

Phân loại văn bản bán giám sát thông qua tự thử nghiệm

Đại học Payam
Karisani Emory
payam.karisani@emory.edu

Đại học Negin
Karisani Purdue
nkarisan@purdue.edu

TRƯỜNG

Chúng tôi trình bày một mô hình học tập bán giám sát thần kinh có tên là Tự tiên đoán tạo. Mô hình của chúng tôi được lấy cảm hứng từ al gorithm tự đoán tạo cổ điển. Tuy nhiên, trái ngược với tự đoán tạo, Self-Pretraining là không có ngữ cảnh, nó có thể cập nhật niềm tin của mình về các tài liệu được dán nhãn trước đó và có thể đối phó với vấn đề trôi dạt ngữ nghĩa. Tự tiên thử nghiệm là lặp đi lặp lại và bao gồm hai bộ phân loại. Trong mỗi lần lặp lại, một bộ phân loại sẽ vẽ một tập hợp ngẫu nhiên các tài liệu chưa được gắn nhãn và gắn nhãn chúng. Tập hợp này được sử dụng để khởi tạo thứ hai bộ phân loại, để được đào tạo thêm bằng bộ tài liệu được dán nhãn. Thuật toán tiến hành lần lặp tiếp theo và vai trò của bộ phân loại được đảo ngược. Để cải thiện luồng thông tin qua các lần lặp và cũng để đối phó với vấn đề trôi dạt ngữ nghĩa, Tự luyện trước sử dụng một quy trình chất lọc lặp đi lặp lại, chuyển hy pothes qua các lần lặp, sử dụng mô hình đoán tạo hai giai đoạn, sử dụng lịch trình tốc độ học tập hiệu quả và sử dụng phương pháp heuristic chuyển đổi nhãn giả. Chúng tôi đã đánh giá mô hình của mình trong ba bộ dữ liệu truyền thông xã hội có sẵn công khai. Các thử nghiệm của chúng tôi cho thấy rằng Tự kiểm tra trước hoạt động tốt hơn các bộ phân loại bán giám sát hiện đại hiện có trên nhiều cài đặt. Mã của chúng tôi có sẵn tại https://github.com/p-karisani/self_pretraining.

KHÁI NIỆM CCS

• Hệ thống thông tin Sao chép kết quả tìm kiếm; Mạng xã hội; Lọc tài liệu; Khai thác thông tin; Phân cụm và phân loại; Tìm kiếm hàng xóm gần nhất.

TỪ KHÓA

phân loại, học tập bán giám sát, khai thác phương tiện truyền thông xã hội

1. GIỚI THIỆU

Bộ phân loại văn bản bán giám sát đã đạt được thành công đáng kể trong vài năm qua do khả năng tổng quát hóa của mạng nơ-ron cao. Mặc dù các bộ phân loại hiện đại thường dựa vào các tập huấn luyện lớn, việc giới thiệu các phép nhúng từ ngữ theo ngữ cảnh và đoán trước mô hình ngôn ngữ [18, 41, 43] đã làm giảm đáng kể nhu cầu chú thích dữ liệu thủ công. Tuy nhiên, các mô hình thần kinh hiện đại vẫn có xu hướng bị quá tải, đặc biệt là ở những khu vực có mô hình ngôn ngữ chuyên biệt và thưa thớt. Các lĩnh vực này bao gồm, nhưng không giới hạn ở: lĩnh vực pháp lý [26], lĩnh vực y tế [34] và lĩnh vực truyền thông xã hội [3].

Tự thuộc vào nhiệm vụ hiện tại, một giải pháp để giải quyết vấn đề này là tự động xây dựng một tập dữ liệu lớn - và có lẽ ồn ào [20], tuy nhiên, điều này không phải lúc nào cũng khả thi [59]. Một cách tiếp cận phương pháp hơn n là sử dụng các kỹ thuật cải thiện khả năng tổng quát hóa. Các kỹ thuật này bao gồm khai thác các phép nhúng từ thần kinh [29],

tăng dữ liệu [6], và thích ứng miền [2]. Khai thác dữ liệu không có vành đai [9, 58] cũng là một cách tiếp cận bổ sung. Trong nghiên cứu này, chúng tôi bổ sung vào phần nội dung tài liệu về học bán giám sát bằng cách sử dụng các thuộc tính của mạng nơ-ron và đề xuất một cách mới để sử dụng dữ liệu không được gắn nhãn. Chúng tôi tập trung vào một trong những lĩnh vực đang bị thiếu hụt dữ liệu đoán tạo, tức là khai thác mạng xã hội. Ngoài việc thiếu dữ liệu đoán tạo, tiến trình trong lĩnh vực này còn bị cản trở bởi độ dài tài liệu ngắn, mô hình ngôn ngữ không chính thức và sự lựa chọn điển hình là mơ hồ của các từ vựng. Những phẩm chất này làm cho các nhiệm vụ trên mạng xã hội trở thành một giữ ống thử nghiệm phù hợp để đánh giá các thuật toán học bán giám sát.

Thuật toán của chúng tôi, được gọi là Tự đoán tạo trước, được lấy cảm hứng từ mô hình tự đoán tạo [58]. Tư duy tự như tự đoán tạo, thuật toán của chúng tôi là lặp đi lặp lại và trong mỗi lần lặp lại chọn một tập hợp các tài liệu không được gắn nhãn để dán nhãn. Tuy nhiên, trái ngược với tự đoán tạo, thuật toán của chúng tôi là không có ngữ cảnh. Do đó, nó không xếp hạng các tài liệu không được gắn nhãn dựa trên những dự đoán của họ. Điều này làm cho thuật toán của chúng tôi đặc biệt phù hợp với các mô hình mạng nơ-ron do các đầu ra được hiệu chỉnh kém của chúng [35]. Ngoài ra, thuật toán của chúng tôi có thể đối phó với vấn đề trôi dạt ngữ nghĩa [12]. Nghĩa là, nó có khả năng chống lại tiếng ồn trong các nhãn giả khi số lần lặp lại tăng lên và tỷ lệ lỗi của bộ phân loại bên dư đi tăng lên. Hơn nữa, Tự tiên đoán tạo có khả năng sửa đổi nhãn của các tài liệu được dán nhãn trước đó. Để đạt được những điều này, mô hình của chúng tôi sử dụng quy trình chuyển đổi lặp đi lặp lại, tức là, trong mỗi lần lặp, thông tin thu được trong các lần lặp trước đó được chất lọc vào bộ phân loại. Nó chuyển một giả thuyết qua các lần lặp lại và sử dụng mô hình học hai giai đoạn, trong đó tập hợp các nhãn giả được sử dụng để khởi tạo trình phân loại và tập hợp các tài liệu có nhãn được sử dụng để tinh chỉnh trình phân loại. Ngoài ra, Self-Pretraining điều chỉnh một lịch trình tốc độ học mới lạ để tích hợp hiệu quả hai bộ ví dụ đoán tạo ồn ào và không gây tiếng ồn. Cuối cùng, để giảm thiểu hơn nữa tác động của các nhãn giả ồn ào trong mỗi lần lặp lại, mô hình của chúng tôi biến đổi phân phối nhãn giả sao cho nó phản ánh sự phân bố của các nhãn trong các lần lặp trước đó.

Các thử nghiệm của chúng tôi trong ba bộ dữ liệu Twitter công khai cho thấy rằng Tự thử nghiệm vượt trội so với hiện đại trong các cài đặt nhiều nơi chỉ có vài trăm tài liệu được gắn nhãn. Điều này có ý nghĩa quan trọng, xét đến việc bộ định lượng nhóm cơ bản của thuật toán của chúng tôi và tất cả các mô hình cơ sở là BERT [18] đã sử dụng đoán tạo trước mô hình ngôn ngữ, và do đó, thực hiện bất kỳ cải tiến nào đối với các dự đoán cơ sở là rất khó khăn. Chúng tôi cũng thực hiện một loạt các thử nghiệm toàn diện để khẳng định tốt hơn các phẩm chất của Tự tiên đoán tạo. Đặc biệt, chúng tôi chứng minh sự mạnh mẽ của mô hình của chúng tôi đối với tiếng ồn trong các nhãn giả.

Những đóng góp trong nghiên cứu của chúng tôi như sau: 1) Chúng tôi đề xuất một khung học tập bán giám sát mới có tên là Tự luyện trước. Mô hình của chúng tôi dựa trên mô hình tự đoán tạo, tuy nhiên, nó không có ngữ cảnh, nó có thể đối phó với vấn đề trôi dạt ngữ nghĩa và cũng có thể sửa đổi các tài liệu đã được gắn nhãn trước đó. Theo hiểu biết của chúng tôi,

Tự tiên đào tạo là mô hình đầu tiên giải quyết những nhược điểm này trong một khuôn khổ thống nhất. 2) Chúng tôi đề xuất một lịch biểu tốc độ học tập mới để tích hợp hiệu quả quy trình tối ưu hóa với quy trình học tập bán giám sát hai giai đoạn của chúng tôi. 3) Để giảm thiểu hơn nữa vấn đề trôi dạt ngẫu nhiên, chúng tôi lập mô hình phân phối lớp của các nhãn giả như một quá trình ngẫu nhiên qua các lần lặp pping bootstrap và đề xuất một cách tiếp cận mới để chuyển đổi các phân phối lớp. 4) Chúng tôi thực hiện một bộ thử nghiệm toàn diện trên ba bộ dữ liệu Twitter có sẵn công khai và chứng minh rằng mô hình của chúng tôi hoạt động tốt hơn một số dự định cơ sở hiện đại nhất trong nhiều cài đặt.

Nghiên cứu của chúng tôi rõ ràng đã thúc đẩy sự tiến bộ trong phân loại văn bản bán giám sát. Chúng tôi tin rằng các ý tưởng được trình bày trong bài báo của chúng tôi có thể được áp dụng cho các lĩnh vực khác, ví dụ: phân loại hình ảnh. Công việc trong tương lai có thể khám phá hướng này. Trong phần tiếp theo, chúng tôi cung cấp một cái nhìn tổng quan về các nghiên cứu liên quan và làm nổi bật các phẩm chất của Tự tiên đào tạo.

2 CÔNG VIỆC LIÊN QUAN

Dữ liệu chưa được gắn nhãn trong học tập bán giám sát. Dữ liệu không được gắn nhãn có thể được khai thác theo nhiều cách. Nó có thể được sử dụng như một siêu nguồn thông tin [21], nó có thể được sử dụng như một bộ điều chỉnh [56], hoặc nó có thể được sử dụng trong cài đặt điều chỉnh miền để tạo mối tương quan giữa nguồn và dữ liệu đích [51]. Mối quan tâm gần đây hơn đối với tài liệu là tự giám sát, trong đó một nhiệm vụ khép kín được xác định sao cho không cần chú thích thủ công. Ví dụ của các nhiệm vụ như vậy là đào tạo trước mô hình ngôn ngữ [18, 41] trong NLP, và học tương phản trong xử lý hình ảnh [15, 46]. Từ một góc độ khác, các nghiên cứu tự giám sát có thể được phân loại thành các phương pháp tiếp cận theo nhiệm vụ [10] và theo nhiệm vụ cụ thể [22]. Điều này đã làm nảy sinh khái niệm về mô hình “prerain, sau đó là finetune”. Chúng tôi tích hợp mô hình này vào thuật toán tự đào tạo. Khởi động trong học tập bán giám sát. Tự đào tạo là phương pháp học tập bán giám sát lâu đời nhất [14] ra đời từ năm 1965 [48]. Ý tưởng này tái xuất hiện trong công trình cụ thể của Yarowsky [58] cho các nhiệm vụ NLP vào năm 1995, và một lần nữa trong cộng đồng thị giác máy tính vào năm 2013 dưới dạng nhãn giả [33]. Thuật toán này là một trình bao bọc liên tục sử dụng một thuật toán được giám sát làm mô hình cơ bản. Có nhiều giả định trong đó việc tự đào tạo - và nói chung là học tập bán giám sát - được kỳ vọng sẽ hoạt động tốt. Ví dụ, giả định về độ trơn cho biết nếu hai điểm dữ liệu 1 và 2 gần nhau, thì các dự đoán 1 và 2 của chúng cũng phải gần nhau - giả định này là cơ sở của các thuật toán như MixUp [60] và MixMatch [8]. Như chúng ta thảo luận trong phần tiếp theo, một khía cạnh không thỏa mãn của việc tự đào tạo là nó dựa vào các thuộc tính của mô hình dự đoán cơ bản, ví dụ, các phân phối đầu ra của mô hình. Đã có những nỗ lực để giải quyết nhược điểm này. Ví dụ, điều chỉnh [1] có thể được sử dụng để giảm bớt ảnh hưởng của các ứng viên ồn ào, hoặc trong bối cảnh học tập chuyển đổi, mật độ của các điểm dữ liệu không được gắn nhãn có thể được kết hợp để giảm thiểu vấn đề này [49].

Trong vài năm qua, các nghiên cứu đã khám phá hiệu quả của mạng nơ-ron như một mô hình dự đoán cơ bản trong quá trình tự đào tạo. Một biến thể mạng nơ-ron của đồng đào tạo [9] được đề xuất trong [42]. Trong [30], các tác giả đề xuất một khuôn khổ để tích hợp lợi thế kiến trúc của con người với đồng đào tạo. Trong [55], một biến thể học tăng cường của đồng đào tạo được đề xuất. Trong [44], một biến thể mạng nơ-ron của

đào tạo tri với sự bất đồng [50] được trình bày, và nó được chỉ ra rằng sự kết hợp là một cơ sở mạnh mẽ đáng ngạc nhiên trong bối cảnh thích ứng chính. Các tác giả trong [13] đề xuất sử dụng điểm phản trầm thay vì điểm tin cậy để chọn

nhân giả; và các tác giả trong [39] sử dụng mạng nơ-ron Bayes để chọn các nhãn giả ít tin cậy nhất trong mỗi lần lặp lại. Trong [4], một chiến lược lấy mẫu tài liệu mới để tự đào tạo được đề xuất. Mô hình, ngoài độ tin cậy của trình phân loại, sử dụng các kỹ thuật đào tạo trong đó các tài liệu không được gắn nhãn được gắn nhãn gần đúng. Trong [5], các tác giả đề xuất tích hợp MixUp [60] với việc lấy mẫu quá mức các ví dụ huấn luyện la beled. Họ cho thấy rằng tự đào tạo thực sự là một cơ sở rất tốt so với các kỹ thuật chính quy hóa và tăng cường dữ liệu thông thường. So với các nghiên cứu này, Tự thử nghiệm là mô hình đầu tiên sử dụng quá trình chuyển đổi mô hình [25] cùng với một giả thuyết để chuyển thông tin qua các lần lặp lại, cho phép nó có khả năng sửa đổi các nhãn giả. Nó tích hợp mô hình đào tạo trước / tinh chỉnh với tự đào tạo, sử dụng quy trình tối ưu hóa đầy đủ cùng với kỹ thuật nhiễu loạn để giảm thiểu tác động tiêu cực của các nhãn giả ồn ào.

Các nghiên cứu liên quan chặt chẽ khác. Ngoài các nghiên cứu trên, Self-Pretraining cũng liên quan đến các nghiên cứu về chuyển đổi mô hình [25] và tổ hợp thời gian [32]. Chuyển đổi mô hình đã được đề xuất trong [11, 25] để chuyển kiến thức từ mô hình này sang mô hình khác. Trong [16], các tác giả chỉ ra rằng việc chuyển giao kiến thức của một mạng lớn, được đào tạo bởi một nhiệm vụ tự giám sát, sang một mạng nhỏ cải thiện khả năng tổng quát hóa. Đóng góp chính của họ là cho thấy rằng các mô hình lớn được đào tạo dễ dàng hơn, và do đó, có thể được sử dụng như một proxy để đào tạo các mạng nhỏ. Mô hình của họ không lặp lại và không khám phá dữ liệu chưa được gắn nhãn để trích xuất thông tin mới. Các mạng tái sinh đã được đề xuất trong [19], các tác giả cho thấy rằng chỉ cần loại bỏ mạng nơ-ron vào chính nó sẽ cải thiện hiệu suất. Mô hình của họ không phải là một thuật toán bán giám sát và không được đề xuất để khai thác dữ liệu không được gắn nhãn. Các tác giả trong [57] chỉ ra rằng thuật toán tự huấn luyện thần kinh thường xuyên có thể được cải thiện bằng cách thêm nhiễu vào mô hình. Tương tự như công việc của chúng tôi, chúng cho phép các nhãn giả phát triển qua các lần lặp lại. Ngoài bước này, họ không đề xuất bất kỳ sửa đổi nào đối với thuật toán tự đào tạo. Ngoài ra, hiệu quả của mô hình của họ không được khám phá trong cài đặt bán giám sát. Một cách tiếp cận rất gần với nghiên cứu này được trình bày trong [23], nơi các tác giả một lần nữa chỉ ra rằng việc thêm nhiễu vào biểu diễn bên trong của mô hình sẽ nâng cao hiệu suất tự đào tạo. Dân nhạc tạm thời đã được đề xuất trong [32]. Các tác giả đề xuất duy trì mức trung bình dự đoán trên mỗi mẫu của dữ liệu không được gắn nhãn trong các kỳ nguyên và hạn chế phương sai dự đoán. Mô hình của họ không dựa trên việc tự đào tạo, không có chiến lược để tách biệt dữ liệu được gắn nhãn khỏi dữ liệu chưa được gắn nhãn và trở nên khó sử dụng khi sử dụng tập dữ liệu lớn. Các tác giả trong [52] giải quyết độ phức tạp cao của việc tổng hợp theo thời gian bằng cách cập nhật trọng số của mô hình qua các kỳ nguyên, thay vì lưu trữ các dự đoán.

3 BÀI HỌC ĐƯỢC GIÁM SÁT BẮC NHẤT QUA

TỰ PHÁT HIỆN

Chúng tôi bắt đầu phần này bằng cách cung cấp tổng quan về Tự đào tạo trước và nêu bật những điểm khác biệt của nó so với thuật toán tự đào tạo.

Sau đó, chúng tôi giới thiệu một loạt các chiến lược để khắc phục những hạn chế của vanilla Self-Pretraining¹.

Trong thuật toán tự đào tạo [58], có sẵn một tập hợp nhỏ gồm các tài liệu được gắn nhãn và một tập hợp lớn các tài liệu không được gắn nhãn. cho tập huấn. Thuật toán lặp đi lặp lại và trong mỗi lần lặp lại, mô hình dự đoán được đào tạo trên tập hợp hiện tại và được sử dụng để theo xác suất nhãn tập hợp hiện tại. Đã đưa ra siêu tham số

là ngưỡng tin cậy tối thiểu, các tài liệu chắc chắn nhất và các nhãn giả liên quan của chúng được chọn để được tăng cường với bộ. Quy trình này được lặp lại cho đến khi tiêu chí nhất định được đáp ứng. Có ba nhược điểm với thuật ngữ này : 1) Vấn đề trôi dạt ngữ nghĩa [12], nơi ngay cả tác động tiêu cực của các nhãn giả ồn ào làm lu mờ lợi ích của kết hợp dữ liệu không được gắn nhãn. 2) Phụ thuộc vào hiệu chuẩn mô hình. Nếu bộ phân loại bên dự đoán không thể tạo mô hình chính xác cho lớp do đó, nó sẽ không thể xếp hạng chính xác các uments tài liệu ứng viên, ví dụ, trong trường hợp mạng nơ-ron [35]. 3) Không thể để sửa đổi các nhãn giả sau khi chúng được gắn cho nhãn chưa được gắn nhãn tài liệu và được tăng cường với tập hợp các tài liệu được dán nhãn. Thậm chí mặc dù tồn tại các kỹ thuật để giải quyết những thách thức này theo các điều kiện nhất định, ví dụ, điều chỉnh [1] để hiệu chuẩn mô hình kém hoặc khởi động độc quyền lẫn nhau [17] cho sự trôi dạt ngữ nghĩa, để kiến thức của chúng tôi, Tự tiên đào tạo là khung thống nhất đầu tiên để địa chỉ cả ba.

Thuật toán của chúng tôi là lặp đi lặp lại và sử dụng hai mạng nơ-ron làm bộ phân loại bên dự đoán. Thuật toán minh họa quá trình tự tiên đào tạo trong nó hình thức cơ bản. Ban đầu, tập hợp được sử dụng để huấn luyện mạng 1 (Dòng 2), sau đó các tham số của 1 được sao chép vào mạng 2 (Dòng 5). Trong bước tiếp theo, một tập hợp các tài liệu không được gắn nhãn sẽ được rút ngẫu nhiên từ (Dòng 7). Tập hợp này được gắn nhãn bằng 2 và được sử dụng dọc theo tập hợp để đào tạo lại² 1 (Dòng 8). Vai trò của hai mạng được đảo ngược trong lần lặp tiếp theo. Trong mỗi lần lặp lại, kích thước mẫu được tăng lên bởi (Dòng 6) và thuật toán dừng khi tập mẫu bao gồm toàn bộ. Cuối cùng, nhóm 1 và 2 có thể được sử dụng để gắn nhãn các tài liệu không nhìn thấy - chúng tôi đã sử dụng giá trị trung bình của lớp của chúng phỏng đoán.

Thuật toán 1 Tổng quan về Vanilla Self-Pretraining

2: 1
3:
4: lặp lại
5: 2
6:

Thuật toán 1 có hai ưu điểm: 1) Để chọn các nhãn giả phân phối giai cấp không được tính đến, do đó, có không có ràng buộc về năng lực của trình phân loại trong việc xếp hạng các tài liệu. Ngoài ra, điều này ngăn không cho mô hình lặp lại

¹Chúng tôi tập trung vào các vấn đề phân loại nhị phân. Lưu ý rằng theo định nghĩa, quá trình tự đào tạo thần kinh đòi hỏi sự khởi động lại và đào tạo lại trong mỗi lần lặp [44], do đó thuật toán của chúng tôi có thể so sánh với các mô hình tự đào tạo khác về thời gian chạy.

chọn một tập hợp cố định gồm các tài liệu không được gắn nhãn trong mỗi lần lặp lại - nghĩa là tập hợp các nhãn giả có độ tin cậy cao. 2) Thông tin đó là được chuyển qua các lần lặp lại ở dạng giả thuyết hơn là hơn một tập hợp các nhãn giả cố định. Do đó, mô hình tin tư ởng về các nhãn giả có thể phát triển theo thời gian - các nhãn giả thì không được tăng cường với tập hợp các tài liệu được gắn nhãn. Mặt khác, thuật toán này có một nhược điểm đáng kể và đó là vấn đề trôi dạt ngữ nghĩa. Trên thực tế, lấy mẫu ngẫu nhiên từ tập hợp tài liệu không có nhãn làm trầm trọng thêm vấn đề này bằng cách giới thiệu nhãn nhiễu và đẩy giả thuyết đã chuyển về phía điểm tối ưu phụ. Trong phần sau, chúng tôi khai thác mạng nơ-ron các thuộc tính và giới thiệu một loạt các chiến lược để đối phó với điều này vấn đề và cũng để tăng cường luồng thông tin trên các lần lặp lại.

3.1 Chuyển giao giả thuyết và lặp lại
Chương cất

Tự tiên đào tạo chuyển giao một giả thuyết - một chức năng đã học - từ một lần lặp đến lần lặp tiếp theo. Trong mỗi lần lặp lại, giả thuyết này được sử dụng để tạo một cái mới bằng cách tạo một tập hợp các nhãn giả và bổ sung chúng với tập hợp các tài liệu được gắn nhãn. Mặc dù tiêu chí cuối cùng là tối đa hóa tiện ích của mô hình, ngăn hạn mục tiêu trong mỗi lần lặp lại không nhất thiết phải đưa ra dự đoán chính xác nhưng phải cẩn thận chuyển giao kiến thức từ mô hình này sang mô hình khác. Hai quy trình này không nhất thiết phải phù hợp với từng khác, vì cái trước có thể dựa vào kết quả của người học và sau này có thể dựa vào chính quy trình học tập. Do đó, các nhãn phân loại tốt hơn, mặc dù có nhiều thông tin, nhưng không đủ biểu đạt để chuyển toàn bộ kiến thức từ lần lặp này sang lần lặp tiếp theo. Các tác giả trong [11, 25] đề xuất một thuật toán gọi là mô hình phân phối để chuyển kiến thức từ một mô hình lớn (được gọi là giáo viên) sang một mô hình nhỏ (được gọi là học sinh). Quá trình chuyển cất mô hình dựa trên lập luận rằng phân phối lớp mang một lượng đáng kể thông tin liên quan đến ranh giới quyết định của trình phân loại. Đối với lặp trước, với một tài liệu được gắn nhãn tích cực, nó không phải là tầm thường để thông tin để biết rằng nếu dự đoán của lớp là 95% tích cực hoặc 65% dự đoán tính. Các tác giả trong [25] sử dụng phương pháp chuyển cất mô hình để chuyển kiến thức từ mạng này sang mạng khác bằng cách sửa đổi softmax lớp như sau:

$$= \frac{\exp \text{---}}{\text{---}}$$

Trong kinh nghiệm

(1)

đầu là logit thứ i của lớp cuối cùng, là số lớp và là dự đoán của lớp. Siêu tham số được gọi là nhiệt độ và được giới thiệu để làm trơn các dự đoán của lớp. Nhiệt độ cao hơn dẫn đến entropy cao hơn trong các dự đoán. Điều này đặc biệt mong muốn, vì mạng nơ-ron được biết là có entropy thấp trong dự đoán của họ [35]. Với lập luận ở trên, chúng tôi sử dụng sự chất lọc mô hình trong Tự tiên đào tạo và chất lọc hiệu quả các lần lặp trước đó thành mạng sinh viên 1. Do đó, trong mỗi lần lặp, thay vì sử dụng dự đoán khó của giáo viên- 2 về các tài liệu không được gắn nhãn, chúng tôi sử dụng các dự đoán mềm dọc theo tập hợp để đào tạo mạng lưới sinh viên- Thuật toán 1, Dòng 8.

3.2 Học tập bán giám sát hai giai đoạn

Như chúng tôi đã đề cập trước đó, tự đào tạo bị trôi dạt ngữ nghĩa vấn đề. Sự cố này xảy ra khi các lỗi chủ yếu do các nhãn giả tích lũy qua các lần lặp lại và cuối cùng làm mất đi ranh giới của bộ phân loại. Mặc dù độ tin cậy tối thiểu ngữ nghĩa có thể có khả năng ngăn chặn các nhãn giả giả mạo từ vào tập huấn luyện, khi tập hợp phát triển về kích thước thì xác suất của các tài liệu ghi nhãn sai tăng tỷ lệ nghịch. Vấn đề này thậm chí còn nghiêm trọng hơn trong mô hình của chúng tôi, vì nó không có ngữ nghĩa. Một người ngày thơ giải pháp là gán trọng số thấp hơn cho các nhãn giả, tuy nhiên, chúng tôi đã quan sát thấy trong các thử nghiệm của mình rằng cách tiếp cận này không hiệu quả đủ để giải quyết vấn đề cơ bản.

Để giảm thiểu vấn đề này, một giải pháp là xử lý tập hợp giả nhãn và tách thông tin mẫu thuần với thông tin được lưu trữ trong tập hợp. Xóa phần này của nhãn giả có thể làm giảm tỷ lệ lỗi và sau đó cải thiện dấu hiệu giả trong lần lặp hiện tại. Để thực hiện điều này, chúng tôi khai thác hiện tượng quên thảm khốc trong mạng nơ-ron [31, 36]. Sự lãng quên nghiêm trọng xảy ra trong quá trình học liên tục thiết lập nơi mạng được đào tạo về một loạt nhiệm vụ. Mỗi khóa đào tạo thủ tục cập nhật các tham số của mô hình để đáp ứng các yêu cầu của hàm mục tiêu và các cập nhật trong tác vụ hiện tại có thể mâu thuẫn và xóa thông tin liên quan đến trước đó các nhiệm vụ. Tuy nhiên, hiệu ứng này thường không mong muốn trong bối cảnh của Tự nhiên thử nghiệm, chúng tôi sử dụng cơ chế này làm proxy để xây dựng phân cấp thông tin trong mạng. Do đó, chúng tôi tạo ra một sửa đổi nhỏ trong Thuật toán 1. Thay vì tổng hợp tập hợp nhãn giả với tập hợp các tài liệu được gắn nhãn - Dòng 8 - trước tiên chúng tôi sử dụng tập hợp các nhãn giả để khởi tạo - đào tạo - mạng hiện tại 1, và sau đó đào tạo thêm bằng cách sử dụng tập hợp các tài liệu được gắn nhãn. Việc phân chia quy trình đào tạo thành hai giai đoạn giới thiệu một thách thức mới và đó là khả năng cập nhật hoàn toàn các tham số mạng để tìm hiểu các quy định trong tập hợp của các tài liệu được dán nhãn. Để tránh điều này, chúng tôi đề xuất sử dụng chức năng mục tiêu trong khi đào tạo mô hình 1 bằng cách sử dụng bộ:

$$L = (1 - \alpha) \left(\sum_{i=1}^n \log(1 - p_i) \right) + \alpha \sum_{i=1}^n \log(p_i) \tag{2}$$

số lượng tài liệu trong bộ ở đầu tiên, là nhãn thực của tài liệu, là dự đoán lớp của là dự đoán lớp của đối với nhiệt độ cao như được mô tả trong Phần 3.1 và là dự đoán cấp của 2 đối với cùng nhiệt độ với nhiệt độ của là một siêu tham số để chi phối trọng số tỷ lệ đối của hai số hạng ($0 \leq \alpha \leq 1$). Từ các bậc của số hạng thứ hai trong Phương trình 2 chia theo thứ tự để cân bằng tác động của hai thuật ngữ trong việc truyền ngược, chúng tôi nhân các gradient này với 2 - xem Công thức 1.

Số hạng đầu tiên trong phương trình 2 là entropy chéo giữa nhãn sự thật cơ bản và xác suất lớp của Phần thứ hai 1. thuật ngữ là entropy chéo giữa xác suất lớp của 2 và

1. Hàm mục tiêu này là một nỗ lực để giữ cân bằng giữa thông tin được chuyển từ các lần lặp trước và thông tin được trích xuất từ tập hợp các tài liệu được dán nhãn.

Trong Phần 5, chúng tôi chứng minh rằng các ý tưởng được đề xuất trong phần này gắn kết đáng kể khả năng chống lại quá trình tự thử nghiệm đối với nhiều trong các nhãn giả. Những ý tưởng này có liên quan đến hai loại của các nghiên cứu: 1) Các nghiên cứu về tiền đào tạo mạng nơ-ron [24, 27]. 2) Các nghiên cứu về học theo chương trình [7]. Các nhà nghiên cứu [24, 27] trong cả NLP và cộng đồng tầm nhìn đã chỉ ra rằng một mạng nơ-ron với dữ liệu ngoài miền và sau đó tinh chỉnh nó với dữ liệu mục tiêu có thể đóng góp đáng kể vào hiệu suất. Hai bước này tương tự như hai giai đoạn mà chúng tôi đã mô tả trong phần này. Ngoài ra, công việc của chúng tôi cũng liên quan chặt chẽ đến ý tưởng về việc học theo chương trình [7], nơi cho thấy rằng người học có thể tận dụng thứ tự của các ví dụ đào tạo để học hiệu quả hơn. Mặc dù quá trình tự tiền đào tạo sử dụng cơ chế này, nhưng tiêu chí để xác định thứ tự của các ví dụ đào tạo không dựa trên thuộc tính của các điểm dữ liệu như dựa trên nguồn của nhãn.

3.3 Tỷ lệ học tập Hình thang phải

Trong phần trước, chúng tôi đã sử dụng một cách tiếp cận để giảm thiểu vấn đề trôi dạt ngữ nghĩa bằng cách khai thác sự lãng quên thảm khốc hiện tượng. Chiến lược hai giai đoạn này tạo ra một cơ hội phù hợp để tăng cường quá trình tối ưu hóa. Kể từ khi nhãn giả có khả năng gây ồn ào, chúng tôi đề xuất sử dụng bộ này để khám phá không gian giả thuyết và phát hiện vùng chứa optima cục bộ tốt hơn. Sau đó, tập hợp các tài liệu được gắn nhãn, không bị nhiễu, có thể được sử dụng để phát hiện mục tiêu tối ưu cục bộ.

Với lập luận ở trên, chúng tôi đề xuất sử dụng một hình thang bên phải tỷ lệ học tập - được minh họa trong Hình 1 - như sau:


$$\alpha = \frac{h}{h_{max}}$$
 trong đó biểu thị bước thời gian hiện tại và h là hiện tại số tài liệu đang được xử lý. là tốc độ học tập hiện tại, là tốc độ học ban đầu, là tập hợp các nhãn giả, là tập hợp các tài liệu có nhãn, là số tài liệu giả, và là số tài liệu được dán nhãn.

Tỷ lệ học tập được đề xuất của chúng tôi bao gồm hai giai đoạn: 1) A tốc độ học tập cố định - được gạch ngang trong Hình 1 - nơi các nhãn giả được sử dụng để đào tạo mô hình 1 - xem Thuật toán 1. Trong , các tham số mạng có thể tự do cập nhật, và do đó, người học về cơ bản có thể khám phá không gian giả thuyết. 2) A dần dần tỷ lệ học tập đang giảm - được nghiêng liền nét trong Hình 1 - ở đầu các tài liệu có nhãn được sử dụng để đào tạo thêm mạng. Trong

giai đoạn này, trình tối ưu hóa lắng xuống, do đó, chúng tôi sử dụng các tài liệu được gắn nhãn không có tiếng ồn, vì ngay cả một sự nhiễu loạn nhỏ trong dữ liệu có thể gây ra một tổn thất đáng kể. Có tốc độ học hai giai đoạn cũng tích hợp một cách hữu cơ với hai giai đoạn bán giám sát của chúng tôi quy trình học tập. Kể từ khi tỷ lệ học tập giảm dần, ngăn không cho mục tiêu của nhiệm vụ thứ hai bị xóa hoàn toàn kiến thức đã chuyển từ các lần lặp trước.

3.4 Phân phối lớp quản tính

Mô hình học tập bán giám sát dựa trên dữ liệu không được gắn nhãn làm nguồn thông tin chính. Trong khi các phương pháp này đã thu được kết quả đầy hứa hẹn, họ vốn dĩ có xu hướng trang bị quá mức bất thường trong dữ liệu không được gắn nhãn. Giới thiệu xu hướng quy nạp [38] vào các thuật toán học bán giám sát là một điều phổ biến



đường ngang là tốc độ học của mạng trong quá trình đào tạo bởi các nhân giả và đường nghiêng là tốc độ học

trong quá trình đào tạo bằng các tài liệu được dán nhãn.

cách tiếp cận để tăng cường độ mạnh mẽ của chúng. Ví dụ: ization thông thư ờng theo số liệu [47] hoặc tập hợp theo thời gian [32] là một vài ví dụ. Trong khi những kỹ thuật này có thể đư ợc tích hợp vào Tư ti ền thử nghiệm, trong

Chúng tôi giả thuyết rằng phân phối xác suất lớp của tập hợp các tài liệu không gắn nhãn đợc chọn ngẫu nhiên - Thuật toán 1, Dòng 8- nên phát triển từ từ và tránh chuyển đổi đột ngột qua các lần lặp lại. Đây là một giả định khắc nghiệt, vì phân phối xác suất này cũng phụ thuộc vào các mẫu rút ra. Tuy nhiên, chúng tôi cho rằng đột ngột sự thay đổi trong phân phối này có thể là dấu hiệu của một làn sóng ồn ào nhân giả trong các lần lặp trước. Do đó, chúng tôi hướng tới việc cấm những thay đổi như vậy. Để đạt đợc điều này, chúng tôi giả định việc phân phối xác suất lớp là một quá trình ngẫu nhiên phát triển đồng qua các lần lặp và phân phối xác suất lớp của tài liệu không đợc gắn nhãn trong mỗi lần lặp- 2 () trong Thuật toán 1 - là

Để đơn giản, chúng tôi giả định quy trình chỉ bao gồm một họ của hai biến ngẫu nhiên Gaussian là trạng thái và nhiễu, ở đây x_t và y_t của các nhân giả tích cực và z_t là trạng thái của nhân âm tính nhân giả. Giá trị trung bình mẫu và phương sai của lần lặp i tại t là $\mu_t^{(i)}$ và $\Sigma_t^{(i)}$.

$$\frac{1}{2} = 1$$

trong đó là số lượng nhân giả dư có tính trong lần lặp và là xác suất của nhân giả dư có tính thứ i thuộc về

cho lớp tích cực - rõ ràng là $0,5 \leq$ vì mẫu là tích cực. Tương ứng, giá trị trung bình mẫu và phương sai của - in

$$\frac{\dot{I} = 1}{2} = 1$$

trong đó là số lượng nhân giả âm trong lần lặp lại và là xác suất của nhân giả âm thứ i thuộc về

cho lớp phủ định - lưu ý rằng $0,5 \leq$ và cũng lưu ý rằng với mọi

Trong lần lặp + 1, các phân phối mẫu của ngẫu nhiên biến X_{n+1} và - tiếp tục). Nhưng cập nhật X_{n+1} và X_{n+1} và X_{n+1} này có thể là do sự ngẫu nhiên trong

Dataset	Tập huấn				Thử nghiệm			
	Tweets	Tiêu cực			Tweets	Tiêu cực		
ADR	20624	91%		9%	4992	92%	8%	
Động đất	8166		53%	47%	3502	53%	47%	
Sản phẩm		4503	69%	31%	2114	78%	22%	

khởi tạo mô hình, tính ngẫu nhiên trong tập hợp các tài liệu không có
vành đai đã chọn trong lần lặp lại hoặc một phần do nhiễu

nhân giả đư ợc giới thiệu trong lần lặp lại. Cụ thể hơn n,

phân loại sai của mô hình 2 trong thuật toán lặp -see

1 - sau đó được sử dụng để đào tạo trước mô hình 1, và cuối cùng đã làm sai lệch phân phối lớp của tập hợp các nhãn giả

trong phép lặp + 1. Để giảm bớt tác động của tiếng ồn này, chúng tôi xác định hai phân phối Gaussian và là sự kết hợp⁺ tuyến tính⁻

của các phân phối lớp trong các lần lặp và + 1, và dự án 3
các nhân giả trong +₁ vào trong +₁, và các nhân giả trong - +₁

$$\begin{array}{r} + \\ +1 \\ - \\ +1 \end{array} \quad \begin{array}{r} + \\ + (1) \\ - + (1) \end{array} \quad \begin{array}{r} + \\ +1 \\ - +1 \end{array}$$

đâu là một siêu tham số để điều chỉnh tốc độ mà phân phối khả năng xác suất có

thể phát triển trong mỗi lần lặp lại. Phân phối mới butions và đư ợc xác định giữa các phần $+1$ phối lớp $+1$ trong

sự lặp lại và + 1. Siêu tham số xác định de gree mà tại đó các nhãn giả trong lần lặp + 1 bị xóa trộn

giống với các nhân giả trong lần lặp lại. Bằng cách sử dụng cơ chế này, sự thay đổi đột ngột đột ngột trong việc phân phối nhân giả đư ợc tránh. Chúng tôi thực hiện bư ớc này sau khi chúng tôi tạo các nhân giả sử dụng mô hình 2 và trư ớc khi sử dụng tập hợp này để

Trong Phần 5, chúng tôi chỉ ra rằng thuật toán Tự thử nghiệm, cùng với các kỹ thuật mà chúng tôi đã giới thiệu trong các phần 3.1, 3.2, 3.3 và 3.4 đạt được kết quả hiện đại nhất trong nhiều cài đặt. Ở phần tiếp theo

4 THIẾT LẬP THỰC NGHIỆM

Chúng tôi bắt đầu phần này bằng cách mô tả các tập dữ liệu mà chúng tôi đã sử dụng, sau đó chúng tôi cung cấp tổng quan ngắn gọn về các mô hình cơ sở và cuối cùng

4.1 Bộ dữ liệu

Chúng tôi đánh giá quá trình tự đào tạo trên ba phân loại văn bản Twitter
nhiệm vụ 4 : 1) Giám sát phản ứng có hại của thuốc (ADR). Trong nhiệm vụ này,
mục đích là để phát hiện các tweet thông báo về tác dụng phụ của thuốc.

Tác vụ đư ợc chia sẻ SMM4H. 2) Phát hiện Báo cáo Khủng hoảng (CRD). Trong nhiệm vụ này, mục đích là để phát hiện các tweet đề cập đến một sự kiện liên quan đến thảm họa thiên nhiên. Chúng tôi đã sử dụng tập dữ liệu đư ợc giới thiệu trong [2] về năm 2015 Trận động đất ở Nepal. 3) Nhận dạng mô hình tiêu thụ sản phẩm (PCP). Trong nhiệm vụ này, mục tiêu là xác định các tweet báo cáo cách sử dụng mô hình sản phẩm. Chúng tôi đã sử dụng tập dữ liệu đư ợc giới thiệu trong [28].

3Không có phép chiếu nào đư ợc thực hiện trong lần lắp đầu tiên.

4 Vui lòng tham khảo các bài báo đã trích dẫn để phân tích và thảo luận về những khó khăn của những nhiệm vụ này, chúng tôi bỏ qua chủ đề này.

Bộ dữ liệu ADR và Động đất được phát hành cùng với các bộ thử nghiệm và đào tạo được chỉ định trước. Trong Tập dữ liệu sản phẩm, chúng tôi đã sử dụng tweet published vào năm 2013 và 2014 cho tập huấn luyện và các tweet được xuất bản vào năm 2015 và 2016 cho tập thử nghiệm. Bảng 1 tóm tắt các bộ dữ liệu. Chúng tôi thấy rằng tập dữ liệu Động đất là cân bằng và tập dữ liệu ADR rất mất cân bằng. Tập dữ liệu về Động đất được phát hành cùng với một tập hợp các tweet không được gắn nhãn. Đối với hai tập dữ liệu còn lại, chúng tôi đã sử dụng API Twitter và thu thập dữ liệu 10.000 tweet có liên quan cho mỗi tập dữ liệu được sử dụng làm tập hợp không được gắn nhãn (tập hợp trong Thuật toán 1). Đối với tập dữ liệu ADR, chúng tôi đã sử dụng tên thuốc để thu thập tập hợp không được dán nhãn và đối với tập dữ liệu Sản phẩm, chúng tôi sử dụng truy vấn “cúm VÀ (vắc xin tiềm ngừa HOẶC)” để thu thập tập hợp.

4.2 Dự đoán cơ sở

Chúng tôi so sánh mô hình của mình với sáu dự đoán cơ sở. Dự đoán cơ sở. Cài đặt để đánh giá els mod học bán giám sát phải thực tế. Các mô hình ngôn ngữ theo ngữ cảnh định sẵn là thành phần chính của bộ phân loại văn bản hiện đại. Do đó, chúng tôi đã sử dụng BERT [18] làm dự đoán cơ sở ngây thơ và cũng là bộ phân loại cơ bản cho tất cả các dự đoán cơ sở khác. Lưu ý rằng điều này làm cho bất kỳ cải tiến nào đối với bộ phân loại cơ sở là rất khó khăn, vì cải tiến này phải là tính năng bổ sung. Chúng tôi đào tạo mô hình này trên tập hợp các tài liệu được gắn nhãn và đánh giá trên tập thử nghiệm. Chúng tôi đã sử dụng biến thể cơ sở được đào tạo trước để xuất bản, tiếp theo là một lớp được kết nối đầy đủ và một lớp softmax. Chúng tôi đã sử dụng triển khai Pytorch [54] của BERT; cài đặt giống với các đề xuất trong [18].

Tự đào tạo. Chúng tôi đã đưa vào thuật toán tự đào tạo thống thứ 58], trong đó trong mỗi lần lặp lại, các nhân giả hàng đầu, tuân theo độ tin cậy ngưỡng tối thiểu, được chọn và thêm vào tập hợp được gắn nhãn. Chúng tôi đã sử dụng một phiên bản của Dự đoán cơ sở trong thuật toán này. Tri-training +. Chúng tôi đã đưa vào một biến thể của thuật toán đào tạo ba lần được gọi là đào tạo ba với sự bất đồng [50]. Trong [44], các tác giả chỉ ra rằng mô hình này là cơ sở rất tốt cho việc học bán giám sát. Chúng tôi đã sử dụng ba phiên bản của Dự đoán cơ sở trong thuật toán này. Học hỏi lẫn nhau. Chúng tôi bao gồm mô hình được giới thiệu trong [61]. Mô hình này là một tập hợp, và dựa trên ý tưởng rằng việc tăng entropy của các dự đoán lớp sẽ cải thiện tính tổng quát hóa [40]. Chúng tôi đã sử dụng hai phiên bản của Dự đoán cơ sở trong mô hình này – trong cài đặt song song. Khoảng cách đại diện. Chúng tôi bao gồm mô hình được giới thiệu trong [4]. Mô hình này sử dụng kỹ thuật xếp hàng dọc theo tập hợp xác thực để chọn các tài liệu không được gắn nhãn dễ dàng và cũng đầy đủ thông tin cho nhiệm vụ. Chúng tôi đã sử dụng cách triển khai mô hình này của riêng mình. Đồng phân rã. Chúng tôi đã bao gồm khuôn khổ được giới thiệu trong [30]. Mô hình này sử dụng kiến thức miền để phân tách nhiệm vụ thành một tập hợp các nhiệm vụ con cần giải quyết trong cài đặt nhiều chế độ xem. Chúng tôi đã sử dụng đại diện cấp độ từ khóa và biểu thị cấp độ câu làm hai chế độ xem. Chúng tôi đã sử dụng hai phiên bản của Dự đoán cơ sở trong thuật toán này. Tự tiên đào tạo. Mô hình mà chúng tôi đã giới thiệu trong Phần 3. Chúng tôi đã sử dụng hai phiên bản của Dự đoán cơ sở là 1 và 2.

4.3 Chi tiết thử nghiệm Để đánh giá

các mô hình trong cài đặt bán giám sát, chúng tôi đã lấy mẫu một tập hợp con nhỏ của các tập huấn luyện⁵ và không sử dụng phần còn lại của các tweet. Lưu ý rằng tập hợp còn lại cũng không được sử dụng làm dữ liệu chưa được gắn nhãn – xem Phần 4.1 để biết mô tả về nhóm chưa được gắn nhãn

các bộ. Để lấy mẫu dữ liệu, chúng tôi sử dụng phương pháp lấy mẫu ngẫu nhiên phân tầng để bảo toàn tỷ lệ giữa tài liệu được sinh và tài liệu âm. Chúng tôi cũng đảm bảo rằng tập hợp có nhãn ban đầu là giống hệt nhau cho tất cả các mô hình. chúng tôi lặp lại tất cả các thí nghiệm 3 lần với các hạt ngẫu nhiên khác nhau. Chúng tôi sẽ báo cáo mức trung bình qua các lần chạy. Tất cả các mô hình cơ sở đều sử dụng điều chỉnh [1] với ngưỡng tin cậy ($\epsilon = 0,9$). Tuy nhiên, chúng tôi cũng tăng tuyến tính kích thước của tập mẫu [45], không thêm quá 10% tập huấn luyện hiện tại trong mỗi lần lặp. Trong các thử nghiệm của mình, chúng tôi quan sát thấy rằng hiệu suất của quá trình tự đào tạo và Co-Decomp suy giảm nếu chúng tôi sử dụng toàn bộ tập dữ liệu không được gắn nhãn – do vấn đề trôi dạt ngữ nghĩa. Do đó, chúng tôi giả định số lần lặp lại trong các thuật toán này là một siêu tham số và sử dụng 20% tập hợp được gắn nhãn làm tập xác nhận để tìm giá trị tốt nhất. Tri-training + có tiêu chí dừng nội bộ. Học tập lẫn nhau sử dụng dữ liệu không được gắn nhãn như một bộ điều chỉnh. Spaced-rep yêu cầu một bộ xác nhận cho tiêu chí dừng và cả cho việc lựa chọn ứng viên. Do đó, trong mô hình này, chúng tôi đã sử dụng 20% tập hợp được gắn nhãn làm tập xác nhận. Chúng tôi cũng đặt số lượng hàng đợi là 6, phần còn lại của cài đặt giống hệt với những gì được sử dụng trong [4].

Vì chúng tôi đang thử nghiệm trong cài đặt bán giám sát, chúng tôi đã không thực hiện điều chỉnh siêu tham số đầy đủ. Chúng tôi đã sử dụng tập huấn luyện trong Tập dữ liệu sản phẩm và tìm kiếm các giá trị tối ưu của trong Phương trình 2 và trong Phương trình 3. Giá trị tốt nhất của chúng lần lượt là 0,3 và 0,1. Chúng tôi đặt kích thước bước trong Thuật toán 1 thành 2.000 và nhiệt độ trong Phương trình 1 đến 3. Trong quy trình đào tạo hai giai đoạn của chúng tôi, mục tiêu của bước đầu tiên là khởi tạo mô hình, do đó chúng tôi chỉ đào tạo mạng trong 1 kỷ nguyên. Trong các trường hợp còn lại, bao gồm cả trong mô hình của chúng tôi và các dự đoán cơ sở, chúng tôi đã đào tạo các mô hình trong 3 kỷ nguyên. Ngoại lệ duy nhất là Space-rep, yêu cầu một số kỷ nguyên huấn luyện nhất định với việc dừng lại sớm. Để huấn luyện BERT trong tất cả các trường hợp, chúng tôi đã sử dụng cài đặt giống với cài đặt của tham chiếu [18] –chúng tôi đặt kích thước lô thành 32. Tiếp theo đối số trong [37], chúng tôi sử dụng F1 trong lớp tích cực để điều chỉnh các mô hình. Trong phần tiếp theo, chúng tôi báo cáo F1, Độ chính xác và Thu hồi trung bình của các mô hình trong các lần chạy.

5 KẾT QUẢ VÀ THẢO LUẬN

Chúng tôi bắt đầu phần này bằng cách báo cáo kết quả chính. Sau đó, chúng tôi trình bày một loạt các thí nghiệm mà chúng tôi đã thực hiện để hiểu rõ hơn về các tính chất của Tự tiên luyện.

5.1 Kết quả chính

Bảng 2 báo cáo hiệu suất của Tự thử nghiệm so với dự đoán cơ sở dư ới hai lượng lấy mẫu – tức là 300 và 500 tweet ngẫu nhiên ban đầu – trong ba tập dữ liệu. Chúng tôi thấy điều đó trong tất cả các trường hợp Tự tiên đào tạo là mô hình hàng đầu hoặc ngang hàng với mô hình hàng đầu. Sự khác biệt trong tập dữ liệu ADR là rất đáng kể, tuy nhiên, trong tập dữ liệu Earthquake, sự khác biệt là rất nhỏ. ADR là một tập dữ liệu không cân bằng. Kiểm tra theo từng trường hợp của chúng tôi cũng cho thấy rằng các tweet tích cực trong tập dữ liệu này rất đa dạng, điều này làm cho các mô hình rất dễ bị ảnh hưởng bởi số lượng các ví dụ đào tạo.

Chúng tôi cũng thấy rằng việc học lẫn nhau hoàn toàn không thành công trong tập dữ liệu này. Các thí nghiệm của chúng tôi cho thấy rằng điều này là do sự phân biệt lớp lệch trong tập dữ liệu này⁶. Đáng ngạc nhiên, chúng tôi thấy rằng Spaced-rep đang hoạt động kém trong các thử nghiệm, mặc dù trước đó mô hình này đã được đánh giá trên các nhiệm vụ truyền thống xã hội [4]. Chúng tôi tin rằng lý do

⁵ Việc sử dụng toàn bộ tập hợp các tweet được gắn nhãn biến nhiệm vụ phân loại thành một vấn đề được giám sát, đây không phải là chủ đề nghiên cứu của chúng tôi.


Chúng tôi đã xây dựng hai bộ dữ liệu không cân bằng bằng cách lấy mẫu con từ bộ dữ liệu Earthquake và Product, mô hình này cũng không thành công trong những trường hợp này.

		Tập dữ liệu ADR			Bộ dữ liệu động đất			Bộ dữ liệu sản phẩm			
# Tweets	Cơ sở	F1	Nhớ lại độ chính xác F1		Nhớ lại độ chính xác F1			Thu hồi chính xác			
300	mô hình	0,238	0,237	0,342	0,715	0,692	0,749	0,728	0,696	0,770	
	Tự đào tạo Tri	0,303	0,269	0,350	0,728	0,697	0,762	0,731	0,675	0,798	
	thức + Học hỏi	0,306	0,236	0,448	0,735	0,680	0,799	0,734	0,659	0,828	
	lẫn nhau 0,024 Khoảng cách		0,707	0,012	0,743	0,685	0,814	0,753	0,778	0,730	
	giữa các đại diện đồng	0,258	0,248	0,277	0,721	0,650	0,811	0,727	0,701	0,760	
	phân rã 0,288 Tự đào tạo	0,310	0,397	0,356	0,728	0,722	0,735	0,754	0,756	0,758	
	0,370 Đư ờng cơ sở 0,253 Tự đào tạo		0,440	0,737	0,704	0,772	0,766	0,757	0,777		
500	Tri thức đào tạo 0,412	0,100	0,411	0,746	0,735	0,760	0,740	0,704	0,782		
	Khoảng cách giữa các đại diện đồng	0,300	0,387	0,737	0,765	0,714	0,741	0,739	0,745		
	phân rã Tự đào tạo	0,365	0,420	0,398	0,480	0,747	0,707	0,793	0,758	0,697	0,833
			0,638	0,059	0,751	0,730	0,773	0,767	0,811	0,728	
		0,295	0,274	0,417	0,728	0,694	0,775	0,737	0,693	0,788	
		0,345	0,313	0,388	0,749	0,746	0,752	0,766	0,771	0,764	
			0,483	0,752	0,718	0,789	0,787	0,784	0,792		

Bảng 2: F1, độ chính xác và thu hồi của Tự thử nghiệm trong bộ dữ liệu ADR, Động đất và Sản phẩm so với đư ờng cơ sở các mô hình. Các mô hình đã đư ợc đào tạo trên 300 và 500 bài đăng của ngư ời dùng đư ợc dán nhãn.

k	F1	Thu hồi chính xác	
1000	0,395	0,306	0,565
2000	0,420	0,376	0,483
3000	0,428	0,386	0,485
4000	0,413	0,347	0,537

Bảng 3: Kết quả của quá trình tự tiền đào tạo với các giá trị khác nhau của - số lư ợng nhân giả đư ợc chọn ngẫu nhiên - trong tập hợp thử nghiệm của Bộ dữ liệu ADR. Các mô hình bắt đầu với 500 bài đăng của ngư ời dùng đư ợc dán nhãn.



Hình 2: F1 của bộ phân loại kết quả trong mỗi lần lặp lại Tự thử nghiệm với các giá trị khác nhau của - số lư ợng nhân giả đư ợc chọn ngẫu nhiên. Các giá trị giữa đư ợc nội suy. Các kết quả lại nằm trong bộ thử nghiệm của bộ dữ liệu ADR.

như sau: Mô hình này dựa trên số lư ợng kỳ nguyên đào tạo xây dựng cấu trúc dữ liệu nội bộ để xếp hạng ứng viên tweet. Khi trình phân loại cơ bản là một ngôn ngữ đư ợc đào tạo trư ớc mô hình, ví dụ: bert, việc tăng số lư ợng kỳ nguyên có thể dẫn đến quá mức và do đó, mâu thuẫn với mục đích. Mặt khác, tay, việc dừng sớm cũng ngăn không cho mô hình tách rời thông tin từ các tweet không thông tin.

5.2 Phân tích thực nghiệm

Chúng tôi bắt đầu phần này bằng cách báo cáo ảnh hư ớng của kích thư ớc bư ớc đối với Thuật toán tự thử nghiệm -xem xét 1. Bảng 3 báo cáo F1, độ chính xác, và nhớ lại quá trình Tự thử nghiệm ở các kích thư ớc bư ớc khác nhau trong bộ thử nghiệm của Bộ dữ liệu ADR. Vì bộ dataset này là bộ lớn nhất, chúng tôi báo cáo tất cả thử nghiệm trong tập dữ liệu này. Chúng tôi thấy rằng hiệu suất đư ợc cải thiện lên đến kích thư ớc bư ớc của 3000 tweet không đư ợc gắn nhãn mỗi lần lặp. Chúng ta vẫn không có một lời giải thích cụ thể để biện minh cho xu hư ớng này, vì nó là điều đư ợng nhiên để mong đợi kích thư ớc bư ớc nhỏ hơn mang lại kết quả tốt hơn. Một lý do có thể là nếu tập hợp các nhãn giả nhỏ, mạng hoàn toàn có thể tìm hiểu tiếng ồn trong tập hợp trong quá trình đào tạo trư ớc. Trong Phần 3.2 chúng tôi lập luận rằng đào tạo hai giai đoạn có thể đối phó với vấn đề trôi dạt ngữ nghĩa. Để hỗ trợ lập luận này, chúng tôi báo cáo hiệu suất của các bộ phân loại trung bình 1 ở cuối mỗi sự lặp lại. Hình 2 báo cáo các hoạt động trong quá trình đào tạo cho các kích thư ớc bư ớc khác nhau. Chúng tôi thấy rằng không có kích thư ớc bư ớc nào, hiệu suất giảm xuống khi số lư ợng tweet không đư ợc gắn nhãn tăng lên - the triệu chứng điển hình của trôi dạt ngữ nghĩa.

Quá trình tự tiền luyện dựa trên quá trình chư ơng cấ t lập đi lập lại - Mục 3.1 - đến chuyển kiến thức từ lần lặp này sang lần lặp tiếp theo. Mô hình phân phối lation tận dụng nhiệt độ trong lớp softmax, xem Phư ơng trình 1. Việc tìm ra mức độ mà tham số siêu này có thể ảnh hư ớng đến hiệu suất học là một thông tin hữu ích. Bảng 4 báo cáo hiệu suất mô hình ở các giá trị khác nhau của siêu tham số. Chúng tôi thấy rằng hiệu suất đạt đỉnh là = 5. Trong phần 3.2, chúng tôi đề xuất một hàm mục tiêu và lập luận rằng thuật ngữ thứ hai của hàm ngăn các nhãn cứng của tập huấn luyện khỏi xóa thông tin đư ợc chuyển từ lần lặp trư ớc. Để chứng minh tác động của thuật ngữ thứ hai, trong Bảng 5, chúng tôi báo cáo hiệu suất mô hình ở các giá trị khác nhau của siêu tham số -the trọng số của số hạng thứ hai. Chúng tôi thấy rằng hiệu suất gần như dần dần cải thiện khi chúng ta tăng lên và đạt đỉnh là = 0,4. Đây là chủ yếu là do sự cải thiện về độ chính xác. Trong Phần 3.4, chúng tôi đã đề xuất biến đổi xác suất lớp phân phối trong lần lặp + 1 thành một phân phối mới sembles sự phân phối trong lần lặp lại. Chúng tôi đã tranh luận rằng điều này chuyển đổi có thể giúp giảm thiểu vấn đề trôi dạt ngữ nghĩa thông qua hạn chế mức độ mà các nhãn giả có thể phát triển trong do đó, mỗi lần lặp lại có thể hạn chế tác động tiêu cực của các nhãn giả ồn ào. Trong Bảng 6, chúng tôi báo cáo hiệu suất của mô hình

T	F1	Thu hồi chính xác
2	0,422	0,361 0,514
3	0,420	0,376 0,483
4	0,421	0,356 0,517
5	0,433	0,382 0,506
6	0,422	0,370 0,491

Bảng 4: Kết quả Tự thử nghiệm trong bộ thử nghiệm của bộ dữ liệu ADR ở các giá trị khác nhau của nhiệt độ () để chương cất lập đi lập lại.

	F1	Thu hồi chính xác
0,1	0,425	0,357 0,529
0,2	0,428	0,355 0,541
0,3	0,420	0,376 0,483
0,4	0,438	0,377 0,531
0,5	0,421	0,350 0,534

Bảng 5: Kết quả Tự thử nghiệm trong bộ thử nghiệm của bộ dữ liệu ADR ở các giá trị khác nhau của siêu tham số () cho hai giai đoạn của chúng tôi learning - xem Phụ ơng trình 2.

	F1	Thu hồi chính xác
0,1	0,420	0,376 0,483
0,2	0,422	0,353 0,530
0,3	0,413	0,345 0,518
0,4	0,424	0,355 0,532
0,5	0,429	0,363 0,527

Bảng 6: Kết quả Tự thử nghiệm trong bộ thử nghiệm của bộ dữ liệu ADR ở các giá trị khác nhau của siêu tham số () đối với sự hình thành chuyển tiếp quán tính của các nhân giả - xem Công thức 3.

Đã vô hiệu hóa Bư ớc F1 học	Thu hồi chính xác
hai giai đoạn hình thang	0,339 0,373 0,333
chư ơng cất lập đi lập lại	0,360 0,235 0,770
0,389 biến đổi quán tính	0,320 0,495
	0,420 0,365 0,497

Bảng 7: Kết quả Tự thử nghiệm trong bộ thử nghiệm của bộ dữ liệu ADR sau khi hủy kích hoạt quá trình chư ơng cất (Phần 3.1), quá trình học hai giai đoạn (Phần 3.2), tốc độ học hình thang (Phần 3.3), và biến đổi quán tính (Mục 3.4).

tại các giá trị khác nhau của siêu tham số trong Phư ơng trình 3. Điều này siêu tham số chỉ phối mức độ biến đổi. Chúng tôi thấy rằng hiệu suất đư ợc cải thiện đáng kể khi chúng tôi tăng giá trị của . Cuối cùng, chúng tôi báo cáo một nghiên cứu cất bỏ trong Bảng 7. Trong phần trư ớc thử nghiệm chúng tôi cho thấy rằng hiệu suất tốt hơ n trong tập dữ liệu ADR là có thể đạt đư ợc bằng cách điều chỉnh siêu tham số cụ thể của tập dữ liệu. Tuy nhiên , chúng tôi vẫn mong đợi rằng, với các siêu tham số hiện tại trong ADR, nghiên cứu cất bỏ có thể tiết lộ tầm quan trọng tư ơng đối của các mô-đun Tự thử nghiệm nói chung. Trong thử nghiệm này, chúng tôi đã thay thế mô hình đào tạo hai giai đoạn (Phần 3.2) với dữ liệu đơn giản tăng nhân hiệu và nhân giả. Ngoài ra, chúng tôi đã thay thế tỷ lệ học hình thang bên phải của chúng tôi (Phần 3.3) bằng tỷ lệ học nghiêng mặc định [18]. Chúng tôi đã thay thế quy trình chư ơng cất lập đi lập lại của mình (Phần 3.1) bằng cách sử dụng nhân cứng trong mọi sự lặp lại. Cuối cùng, chúng tôi đã hủy kích hoạt chuyển đổi nhân giả của mình bư ớc (Mục 3.4). Chúng tôi thấy rằng mô hình đào tạo hai giai đoạn và biến đổi quán tính có đóng góp cao nhất và thấp nhất.

Tóm lại, chúng tôi đã cho thấy rằng Tự thử nghiệm trư ớc là kỹ thuật tiên tiến trong nhiều cài đặt. Các tác giả trong [4] chỉ ra rằng các mô hình bán giám sát - mặc dù theo sự thay đổi miền - thư ờng không thành công khi họ đư ợc đánh giá về một nhiệm vụ khác với những gì họ đư ợc ban đầu đề xuất cho. Do đó, họ kết luận rằng những mô hình này nên đư ợc đánh giá trong ít nhất hai tập dữ liệu. Trong nghiên cứu này, chúng tôi đã đánh giá Tự tiền đào tạo trong ba bộ dữ liệu Twitter. Chúng tôi đã chọn những đư ờng cơ sở chắc chắn, tức là Tri-luyện bất đồng [50], Học lẫn nhau [61], Lập lại có Khoảng cách [4], và Đồng phần ữ [30], và cho thấy rằng một số trong số họ không thành công trong một số trư ờng hợp nhất định. Trái ngư ợc với những mô hình này, chúng tôi đã chứng minh rằng Tự tiền đào tạo là mô hình tốt nhất hoặc trên một ngang bằng với mô hình tốt nhất trong mọi thiết lập. Chúng tôi cũng đã báo cáo một loạt các thử nghiệm độc biệt mà chúng tôi đã thực hiện để tiết lộ các phẩm chất của Tự tiền đào tạo. Những thử nghiệm này đã hỗ trợ theo kinh nghiệm tuyên bố rằng chúng tôi đã thực hiện trong suốt.

Nghiên cứu của chúng tôi không phải là hoàn hảo. Để tránh áp đặt bất kỳ ràng buộc nào đối với trình phân loại cơ bản, chúng tôi đã đề xuất rút ngẫu nhiên phần không đư ợc gắn nhãn tài liệu - Thuật toán 1, Dòng 7. Tuy nhiên, nếu ai đó có thể đảm bảo một số thuộc tính phân loại nhất định, sau đó có thể là một lựa chọn phức tạp chính sách sẽ hiệu quả hơ n. Việc áp dụng khuôn khổ của chúng tôi trong các phư ơng thức khác, ví dụ: phân loại hình ảnh, cũng là một phư ơng thức chứ a đư ợc khám phá chủ đề. Công việc trong tư ơng lai có thể điều tra những hư ớng này.

6. KẾT LUẬN

Trong nghiên cứu này, chúng tôi đã đề xuất một mô hình học tập bán giám sát đư ợc gọi là Tự tiền đào tạo. Mô hình của chúng tôi đư ợc lấy cảm hứng từ thuật toán tự đào tạo truyền thống. Tự đào tạo trư ớc sử dụng các thuộc tính của mạng neu ral để đối phó với các vấn đề có hữu của quá trình tự đào tạo. Đặc biệt, nó sử dụng một quy trình chư ơng cất lập đi lập lại để chuyển thông tin fer qua các lần lặp lại. Nó cũng sử dụng hai giai đoạn mô hình đào tạo để giảm thiểu vấn đề trôi dạt ngư ợc nghĩa. Đồng minh bỏ sung, Tự tiền đào tạo sử dụng một lịch trình tốc độ học tập hiệu quả và một heuristic biến đổi nhân giả. Chúng tôi đã đánh giá mô hình của mình trong ba tập dữ liệu Twitter có sẵn công khai và đư ợc so sánh với sáu đư ờng cơ sở, bao gồm cả BERT đư ợc đào tạo trư ớc. Các thí nghiệm cho thấy rằng mô hình của chúng tôi luôn hoạt động tốt hơ n các đư ờng cơ sở hiện có.

SỰ NHÌN NHẬN

Chúng tôi cảm ơn những ngư ời đánh giá ẩn danh vì phản hồi sâu sắc của họ.

NGƯ ỜI GIỚI THIỆU

[1] Steven Abney. 2007. Học tập bán giám sát cho Ngôn ngữ học tính toán (1 ed.). Chapman & Hall / CRC.

[2] Fixoj Alam, Shafiq Joty và Muhammad Imran. 2018. Thích ứng miền với Đào tạo đối phư ơng và Những đồ thị. Trong Kỳ yếu của ACL thứ 56. Hiệp hội Ngôn ngữ học Tính toán, Melbourne, Úc, 1077-1087.

[3] Thayer Alshaabi, David R Dewhurst, và cộng sự. 2020. Buồng dội âm ngày càng phát triển của mạng xã hội: Đo lường động lực lây lan theo thời gian và xã hội cho hơ n 150 ngôn ngữ trên Twitter cho năm 2009-2020. arXiv bản in trư ớc arXiv: 2003.03667 (2020).

[4] Hadi Amiri. 2019. Tự đào tạo thần kinh thông qua sự lặp lại theo khoảng cách. Trong Kỳ yếu của Hội nghị NAACL năm 2019. Minneapolis, Minnesota, 21-31.

[5] Eric Arazo, Diego Ortego, Paul Albert, và cộng sự. 2020. Dân nhân giả và Xu hướng xác nhận trong học tập bán giám sát sâu. Năm 2020 Liên doanh Quốc tế Hội nghị về Mạng thần kinh, IJCNW, ngày 19-24 tháng 7 năm 2020. IEEE, 1-8.

[6] David Bamman và Noah A. Smith. 2015. Bật phát hiện Sarcasm theo ngư ờng cảnh Twitter. Trong Kỳ yếu của ICWSM lần thứ IX. 574-577.

[7] Yoshua Bengio, Jérôme Louradour, Ronan Collobert và Jason Weston. Năm 2009. Giáo trình học. Trong Kỳ yếu của ICML lần thứ 26 (Montreal, Quebec, Canada) (ICML '09). Hiệp hội Máy tính, New York, NY, Hoa Kỳ, 41-48.

[8] David Berthelot, Nicholas Carlini, Ian J. Goodfellow, Nicolas Papernot, Avital Oliver và Colin Raffel. 2019. MixMatch: Phư ơng pháp tiếp cận toàn diện để bán giám sát Học hồi. Tại NeurIPS 2019, 8-14 Vancouver, BC, Canada. 5050-5060.

[9] Avrim Blum and Tom M. Mitchell. 1998. Kết hợp dữ liệu được gán nhãn và không được gán nhãn với đồng dao tạo. Trong *Kỷ yếu của COLT lần thứ mười một*, 1998, Madison, Wisconsin, Hoa Kỳ, 24-26 tháng 7 năm 1998. 92-100.

[10] Tom B Brown, Benjamin Mann, và cộng sự. 2020. Mô hình ngôn ngữ là những người học rất ít. arXiv bản in trước arXiv: 2005.14165 (2020).

[11] Cristian Buciluundefined, Rich Caruana, và Alexandru Niculescu-Mizil. Năm 2006. Nền mô hình. Trong *Kỷ yếu của ACM SIGKDD lần thứ 12 (Philadelphia, PA, Hoa Kỳ) (KDD '06)*. 535-541.

[12] Andrew Carlson, Justin Betteridge, Bryan Kisiel, Burr Settles, Estevam R. Hruschka, và Tom M. Mitchell. 2010. Hướng tới một Kiến trúc cho việc Học Ngôn ngữ Không bao giờ Kết thúc. Trong *Kỷ yếu AAAI lần thứ 24*. 1306-1313.

[13] Paola Cascante-Bonilla, Fuwen Tan, Yanjun Qi và Vicente Ordonez. 2020. Curriculum Labeling: Dân nhân giả theo nhịp độ cho Học tập bán giám sát. arXiv bản in trước arXiv: 2001.06001 (2020).

[14] Olivier Chapelle, Bernhard Schölkopf và Alexander Zien (Eds.). 2006. Học bán có giám sát. Báo chí MIT.

[15] Ting Chen, Simon Kornblith, Mohammad Norouzi và Geoffrey Hinton. Năm 2020. Một khuôn khổ đơn giản để học tự động phần về các hình ảnh đại diện. arXiv bản in trước arXiv: 2002.05709 (2020).

[16] Ting Chen, Simon Kornblith, Kevin Swersky, Mohammad Norouzi và Geoffrey Hinton. 2020. Các mô hình tự giám sát lớn là những người học bán giám sát mạnh mẽ. arXiv bản in trước arXiv: 2006.10029 (2020).

[17] James R Curran, Tara Murphy và Bernhard Scholz. 2007. Giảm thiểu sự trôi dạt ngữ nghĩa với khởi động loại trừ lẫn nhau. Trong *Kỷ yếu của Hội nghị lần thứ 10 của Hiệp hội Ngôn ngữ học Tính toán Thái Bình Dương*, Vol. 6. Bali, 172-180.

[18] Jacob Devlin, Ming-Wei Chang, Kenton Lee, và Kristina Toutanova. 2019. BERT: Đào tạo trước và Máy biến áp hai chiều sâu để hiểu ngôn ngữ. Trong *Proc của NAACL 2019*. 4171-4186.

[19] Tommaso Furlanello, Zachary Chase Lipton, Michael Tschannen, Laurent Itti và Anima Anandkumar. 2018. Born-Again Neural Networks. Trong *Kỷ yếu của ICLR lần thứ 35, Stockholm, Thụy Điển*, ngày 10-15 tháng 7 năm 2018, Vol. 80. 1602-1611.

[20] Roberto Gonzalez-Ibaez, Smaranda Muresan và Nina Wacholder. 2011. Xác định ứng Sarcasm trong Twitter: A Closer Look. Trong *Kỷ yếu của ACL lần thứ 49 (Portland, Oregon) (HLT '11)*. 581-586.

[21] Suchin Gururangan, Tam Dang, Dallas Card, và Noah A. Smith. 2019. Đào tạo trước để biến thể cho Phân loại văn bản bán giám sát. Trong *Kỷ yếu của ACL lần thứ 57. Florence, Ý*, 5880-5894.

[22] Suchin Gururangan, Ana Marasović, Swabha Swayamdipta, Kyle Lo, Iz Beltagy, Doug Downey và Noah A. Smith. 2020. Không ngừng thử nghiệm trước: Điều chỉnh mô hình ngôn ngữ cho miễn và nhiệm vụ. Trong *Kỷ yếu của ACL*.

[23] Junxian He, Jiatao Gu, Jiajun Shen, và Marc'Aurelio Ranzato. 2020. Kiểm tra lại quá trình tự đào tạo để tạo chuỗi thần kinh. Trong *Hội nghị Quốc tế lần thứ 8 về Đại diện trong Học tập, ICLR 2020*, ngày 26 - 30 tháng 4 năm 2020. OpenReview.net.

[24] Dan Hendrycks, Kimin Lee và Mantas Mazeika. 2019. Sử dụng đào tạo trước có thể cải thiện độ chắc chắn và độ không chắc chắn của mô hình. Trong *Kỷ yếu của ICLR lần thứ 36, California, Hoa Kỳ, Vol. 97*. 2712-2721.

[25] Geoffrey Hinton, Oriol Vinyals và Jeff Dean. 2015. Chất lọc kiến thức trong mạng nơ-ron. arXiv bản in trước arXiv: 1503.02531 (2015).

[26] Nils Holzenberger, Andrew Blair-Stanek và Benjamin Van Durme. 2020. Tập dữ liệu về lý luận theo luật định trong việc thi hành luật thuế và trả lời câu hỏi. arXiv bản in trước arXiv: 2005.05257 (2020).

[27] Jeremy Howard và Sebastian Ruder. 2018. Mô hình ngôn ngữ phổ thông Tốt điều chỉnh cho Phân loại văn bản. Trong *Kỷ yếu của ACL thứ 56*. 328-339.

[28] Jiaolei Huang, Michael C Smith, Michael J Paul, Dmytro Ryzhkov, Sandra C Quinn, David A Broniatowski và Mark Dredze. 2017. Kiểm tra các mô hình tiêm phòng cúm trên mạng xã hội. Trong *Hội thảo tại AAAI lần thứ 31*.

[29] Payam Karisani và Eugene Agichtein. 2018. Bạn Thực Sự Vỡ Bại Đau Tim? Hướng tới phát hiện mạnh mẽ các đề cập đến sức khỏe cá nhân trên phương tiện truyền thông xã hội. Trong *Kỷ yếu của Hội nghị World Wide Web 2018 (Lyon, Pháp)*. 137-146.

[30] Payam Karisani, Joyce Ho và Eugene Agichtein. 2020. Phân xử nhiệm vụ do miễn hướng dẫn với tự đào tạo để phát hiện sự kiện cá nhân trên phương tiện truyền thông xã hội. Trong *Kỷ yếu Hội nghị Web 2020 (Đài Bắc, Đài Loan)*. 2411-2420.

[31] James Kirkpatrick, Razvan Pascanu, và cộng sự. 2017. Khắc phục tình trạng lãng quên thăm khám trong mạng nơ-ron. *Kỷ yếu của Viện Hàn lâm Khoa học Quốc gia* 114, 13 (2017), 3521-3526.

[32] Samuli Laine và Timo Aila. 2017. Tập hợp tạm thời cho học tập bán giám sát. Trong *Hội nghị Quốc tế lần thứ 5 về Đại diện Học tập, ICLR 2017, Toulon, Pháp, 24-26 tháng 4 năm 2017, Kỷ yếu theo dõi Hội nghị*.

[33] Dong-Hyun Lee. 2013. Pseudo-label: Phương pháp học bán giám sát đơn giản và hiệu quả dành cho mạng nơ-ron sâu. Trong *Hội thảo về những thách thức trong học tập theo phương pháp giới thiệu*, ICLR, Vol. 3.

[34] Jinhyuk Lee, Wonjin Yoon, và cộng sự. 2019. BioBERT: mô hình biểu diễn ngôn ngữ y sinh được đào tạo trước để khai thác văn bản y sinh. *Tin sinh học* 36, 4 (09 2019), 1234-1240.

[35] Kimin Lee, Kibok Lee, Honglak Lee và Jinwoo Shin. 2018. Khung thống nhất đơn giản để phát hiện các mẫu ngoài phân phối và các cuộc tấn công bất lợi. Những tiến bộ trong hệ thống xử lý thông tin thần kinh 31. 7167-7177.

[36] Michael McCloskey và Neal J. Cohen. 1989. Sự can thiệp thảm khốc trong mạng của các nhà nghiên cứu: Vấn đề học tập tuần tự. *Tâm lý học và Động lực*, Vol. 24. Nhà xuất bản, 109 - 165.

[37] Richard McCreadie, Cody Buntain và Ian Soboroff. 2019. Luồng sự cố TREC: Tìm kiếm thông tin hữu ích trên phương tiện truyền thông xã hội. Trong *Kỷ yếu IS CRAM lần thứ 16, năm 2019*.

[38] Tom M Mitchell và cộng sự. 1997. Máy học. 1997. Burr Ridge, IL: McGraw Hill 45, 37 (1997), 870-877.

[39] Subhabrata Mukherjee và Ahmed Hassan Awadallah. 2020. Tự đào tạo về Nhận thức không chắc chắn về Phân loại văn bản có ít nhãn. arXiv: 2006.15315 [cs.CL]

[40] Gabriel Pereyra, George Tucker, Jan Chorowski, Lukasz Kaiser và Geoffrey E. Hinton. 2017. Quy định hóa mạng lưu ý thần kinh bằng cách trừng phạt các phần phổ biến ra đáng tin cậy. Tại *ICLR lần thứ 5 năm 2017, Toulon, Pháp, ngày 24-26 tháng 4 năm 2017*.

[41] Matthew Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee và Luke Zettlemoyer. 2018. Trình bày từ ngữ theo ngữ cảnh sâu sắc. Trong *Kỷ yếu NAACL 2018. New Orleans, Louisiana, 2227-2237*.

[42] Siyuan Qiao, Wei Shen, Zhishuai Zhang, Bo Wang và Alan Yuille. 2018. Đào tạo Deep Co về Nhận dạng Hình ảnh Bán Giám sát. Trong *Kỷ yếu của Hội nghị Châu Âu về Thị giác Máy tính (ECCV)*.

[43] Colin Raffel và cộng sự. 2019. Khám phá các giới hạn của việc học chuyển tiếp với biến văn bản thành văn bản thống nhất. arXiv bản in trước arXiv: 1910.10683 (2019).

[44] Sebastian Ruder và Barbara Plank. 2018. Cơ sở vững chắc cho việc học bán giám sát bằng thần kinh theo Domain Shift. Trong *Kỷ yếu của ACL lần thứ 56 (Melbourne, Úc)*. Hiệp hội Ngôn ngữ học Tính toán, 1044-1054.

[45] Kuniaki Saito, Yoshitaka Ushiku, và Tatsuya Harada. 2017. Đào tạo Trí bất đối xứng để Thích ứng Miền Không Giám sát. Trong *Kỷ yếu của ICLR lần thứ 34 (Sydney, NSW, Úc) (ICML'17)*. 2988-2997.

[46] M. Sajjadi, M. Javanmardi và T. Tasdizen. 2016. Mất độc quyền lẫn nhau đối với học sâu bán giám sát. Vào năm 2016 IEEE (ICIP). 1908-1912.

[47] Dale Schuurmans và Finnegan Southey. 2002. Các phương pháp dựa trên số liệu để lựa chọn và điều chỉnh mô hình thích ứng. *Học máy* 48, 1 (2002), 51-84.

[48] H Scudder. 1965. Xác suất lỗi của một số máy nhận dạng mẫu thích ứng. *Giao dịch IEEE về Lý thuyết thông tin* 11, 3 (1965), 363-371.

[49] Weiwei Shi, Yihong Gong, Chris Ding, Zhiheng MaXiaoyu Tao và Nanning Zheng. 2018. Học sâu bán giám sát chuyển đổi sử dụng các tính năng tối thiểu. Trong *Kỷ yếu của (ECCV)*. 299-315.

[50] Anders Søgaard. 2010. Đào tạo bán giám sát đơn giản về gers Tag-of-Speech. Trong *Kỷ yếu của ACL 2010 (Uppsala, Thụy Điển)*. Hoa Kỳ, 205-208.

[51] Baochen Sun, Jiashi Feng và Kate Saenko. 2016. Sự trở lại của khả năng thích ứng miền để đáng đáng thất vọng. Trong *Kỷ yếu AAAI thứ ba, ngày 12 - 17 tháng 2 năm 2016, Phoenix, Arizona, Hoa Kỳ*. 2058-2065.

[52] Antti Tarvainen và Harri Valpola. 2017. Giáo viên trung bình là hình mẫu tốt hơn: Mục tiêu nhất quán trung bình theo trọng số cải thiện kết quả học sâu bán giám sát. Những tiến bộ trong hệ thống xử lý thông tin thần kinh 30. 1195-1204.

[53] Davy Weissenbacher và Graciela Gonzalez-Hernandez (Eds.). 2019. *Kỷ yếu Hội thảo Khai thác Truyền thông Xã hội cho Ứng dụng Y tế (#SMM4H) lần thứ tư và Nhiệm vụ được Chia sẻ. Hiệp hội Ngôn ngữ học Tính toán, Florence, Ý*.

[54] Thomas Wolf, Lysandre Debut, và cộng sự. 2019. Người ới văn chuyên của HuggingFace: Xử lý ngôn ngữ tự nhiên tiên tiến nhất. ArXiv abs / 1910.03771 (2019).

[55] Jiawei Wu, Lei Li, và William Yang Wang. 2018. Đồng đào tạo dự đoán cùng cố. Trong *Kỷ yếu NAACL 2018. New Orleans, Louisiana, 1252-1262*.

[56] Qizhe Xie, Zihang Dai, Eduard Hovy, Minh-Thang Luong và Quoc V Le. 2019. Tăng cường dữ liệu không được giám sát để đào tạo tính nhất quán. arXiv bản in trước arXiv: 1904.12848 (2019).

[57] Qizhe Xie, Minh-Thang Luong, Eduard Hovy, and Quoc V. Le. 2020. Tự Đào Tạo Với Sinh Viên Ổn ào Cải thiện Phân loại ImageNet. Trong *Kỷ yếu của Hội nghị IEEE / CVF về Nhận dạng Mẫu và Thị giác Máy tính (CVPR)*.

[58] David Yarowsky. 1995. Không giám sát Word Sense Disambiguation Rivaling Phương pháp giám sát. Trong *ACL thứ 33. Cambridge, Massachusetts, Hoa Kỳ*, 189-196.

[59] Kiran Zahra, Muhammad Imran và Frank O. Ostermann. 2020. Tự động nhận dạng tin nhắn của nhân chứng trên twitter trong các thảm họa. *Xử lý & Quản lý Thông tin* 57, 1 (2020), 102107.

[60] Hongyi Zhang, Moustapha Cissé, Yann N. Dauphin, và David Lopez-Paz. 2018. Mixup: Ví dụ ra ngoài Giảm thiểu rủi ro theo kinh nghiệm. Tại *ICLR lần thứ 6 2018, Vancouver, BC, Canada, 30 tháng 4 - 3 tháng 5, 2018, Kỷ yếu Theo dõi Hội nghị*.

[61] Ying Zhang, Tao Xiang, Timothy M. Hospedales, và Huchuan Lu. 2018. Học hỏi lẫn nhau sâu sắc. Trong *Hội nghị IEEE về khái niệm Thị giác Máy tính và Nhận dạng Mẫu (CVPR)*.