

Phân loại văn bản bán giám sát thông qua tự thử nghiệm

Payam Karisani
đại học Emory
payam.karisani@emory.edu

Negin Karisani
Đại học Purdue
nkarisan@purdue.edu

TRƯỜNG TƯỢNG

Chúng tôi trình bày một mô hình học tập bán giám sát thần kinh gọi là Tự học trước. Mô hình của chúng tôi được lấy cảm hứng từ thuật toán tự đào tạo cổ điển. Tuy nhiên, trái ngược với tự đào tạo, Tự đào tạo trước là không có ngưỡng, nó có khả năng cập nhật niềm tin của mình về các tài liệu được gắn nhãn trước đó và có thể đối phó với vấn đề trôi dạt ngữ nghĩa. Tự tiền thử nghiệm là lặp đi lặp lại và bao gồm hai bộ phận loại. Trong mỗi lần lặp lại, một bộ phận loại sẽ vẽ một tập hợp ngẫu nhiên các tài liệu chưa được gắn nhãn và gắn nhãn chúng. Tập hợp này được sử dụng để khởi tạo bộ phận loại thứ hai, để được đào tạo thêm bởi tập hợp các tài liệu có nhãn. Thuật toán tiến hành lần lặp tiếp theo và vai trò của bộ phận loại được đảo ngược. Để cải thiện luồng thông tin qua các lần lặp lại và cũng để đối phó với vấn đề trôi dạt ngữ nghĩa, Tự tiền luyện sử dụng một quy trình chất lọc lặp đi lặp lại, chuyển các giả thuyết qua các lần lặp lại, sử dụng mô hình đào tạo hai giai đoạn, sử dụng lịch trình tốc độ học tập hiệu quả và sử dụng phương pháp heuristic chuyển đổi nhãn giả. Chúng tôi đã đánh giá mô hình của mình trong ba bộ dữ liệu truyền thông xã hội có sẵn công khai. Các thử nghiệm của chúng tôi cho thấy rằng Tự kiểm tra trước hoạt động tốt hơn các bộ phận loại bán giám sát hiện đại hiện có trên nhiều cài đặt. Mã của chúng tôi có sẵn tại https://github.com/p-karisani/self_pretraining.

KHÁI NIỆM CCS

• Hệ thống thông tin → Kết quả tìm kiếm trùng lặp; Mạng xã hội; Lọc tài liệu; Khai thác thông tin; Phân cụm và phân loại; *Tìm kiếm hàng xóm gần nhất*.

TỪ KHÓA

phân loại, học tập bán giám sát, khai thác phương tiện truyền thông xã hội

1. GIỚI THIỆU

Bộ phận loại văn bản bán giám sát đã đạt được thành công đáng kể trong vài năm qua do khả năng tổng quát hóa của mạng nơ-ron cao. Mặc dù các bộ phận loại hiện đại thường dựa vào các tập huấn luyện lớn, việc giới thiệu các phép nhúng từ ngữ theo ngữ cảnh và đào tạo trước mô hình ngôn ngữ [18, 41, 43] đã làm giảm đáng kể nhu cầu chú thích dữ liệu thủ công. Tuy nhiên, các mô hình thần kinh hiện đại vẫn có xu hướng bị quá tải, đặc biệt là ở những khu vực có mô hình ngôn ngữ chuyên biệt và thưa thớt. Các lĩnh vực này bao gồm, nhưng không giới hạn ở: lĩnh vực pháp lý [26], lĩnh vực y tế [34] và lĩnh vực truyền thông xã hội [3].

Tùy thuộc vào nhiệm vụ hiện tại, một giải pháp để giải quyết vấn đề này là tự động xây dựng một tập dữ liệu lớn – và có lẽ ồn ào [20], tuy nhiên, điều này không phải lúc nào cũng khả thi [59]. Một cách tiếp cận phương pháp hơn là sử dụng các kỹ thuật cải thiện khả năng tổng quát hóa. Các kỹ thuật này bao gồm khai thác các phép nhúng từ thần kinh [29],

tăng dữ liệu [6], và thích ứng miền [2]. Khai thác dữ liệu không được gắn nhãn [9, 58] cũng là một cách tiếp cận bổ sung. Trong nghiên cứu này, chúng tôi bổ sung vào nội dung tài liệu về học bán giám sát bằng cách sử dụng các thuộc tính của mạng nơ-ron và đề xuất một cách mới để sử dụng dữ liệu không được gắn nhãn. Chúng tôi tập trung vào một trong những lĩnh vực được báo cáo là thiếu đủ dữ liệu đào tạo, tức là khai thác mạng xã hội. Ngoài việc thiếu dữ liệu đào tạo, tiến trình trong lĩnh vực này còn bị cản trở bởi độ dài tài liệu ngắn, mô hình ngôn ngữ không chính thức và sự lựa chọn từ vựng điển hình là mơ hồ. Những phẩm chất này làm cho các nhiệm vụ trên mạng xã hội trở thành một giở dờ thử nghiệm phù hợp để đánh giá các thuật toán học bán giám sát.

Thuật toán của chúng tôi, được gọi là Tự tiền thử nghiệm, được lấy cảm hứng từ mô hình tự đào tạo [58]. Tương tự như tự đào tạo, thuật toán của chúng tôi là lặp đi lặp lại và trong mỗi lần lặp lại chọn một tập hợp các tài liệu chưa được gắn nhãn để gắn nhãn. Tuy nhiên, trái ngược với tự đào tạo, thuật toán của chúng tôi là không có ngưỡng. Do đó, nó không xếp hạng các tài liệu không được gắn nhãn dựa trên những dự đoán của họ. Điều này làm cho thuật toán của chúng tôi đặc biệt phù hợp với các mô hình mạng nơ-ron do các đầu ra được hiệu chỉnh kém của chúng [35]. Ngoài ra, thuật toán của chúng tôi có thể đối phó với vấn đề trôi dạt ngữ nghĩa [12]. Đó là, nó có khả năng chống lại tiếng ồn trong *nhân giả* số lần lặp lại tăng lên và tỷ lệ lỗi của trình phân loại bên dưới tăng lên. Hơn nữa, Tự tiền đào tạo có khả năng sửa đổi nhãn của các tài liệu đã được dán nhãn trước đó. Để đạt được những điều này, mô hình của chúng tôi sử dụng quy trình chưng cất lặp đi lặp lại, tức là, trong mỗi lần lặp, thông tin thu được trong các lần lặp trước đó được chất lọc vào bộ phận loại. Nó chuyển một giả thuyết qua các lần lặp lại và sử dụng mô hình học hai giai đoạn, trong đó tập hợp các nhãn giả được sử dụng để khởi tạo trình phân loại và tập hợp các tài liệu có nhãn được sử dụng để tinh chỉnh trình phân loại. Ngoài ra, Self-Pretraining điều chỉnh một lịch trình tốc độ học tập mới để tích hợp hiệu quả hai bộ ví dụ đào tạo ồn ào và không gây tiếng ồn. Cuối cùng, để giảm thiểu tác động của các nhãn giả ồn ào trong mỗi lần lặp lại,

Các thử nghiệm của chúng tôi trong ba tập dữ liệu Twitter công khai cho thấy rằng Tự thử nghiệm vượt trội so với hiện đại trong nhiều cài đặt nơi chỉ có vài trăm tài liệu được gắn nhãn sẵn có. Điều này rất quan trọng, xét rằng trình phân loại cơ bản của thuật toán của chúng tôi và tất cả các mô hình cơ sở là BERT [18] đã sử dụng đào tạo trước mô hình ngôn ngữ, và do đó, thực hiện bất kỳ cải tiến nào so với đường cơ sở là rất khó khăn. Chúng tôi cũng thực hiện một bộ thí nghiệm toàn diện để hiểu rõ hơn về các phẩm chất của Tự thử nghiệm. Đặc biệt, chúng tôi chứng minh sự mạnh mẽ của mô hình của chúng tôi đối với tiếng ồn trong các nhãn giả. Những đóng góp trong nghiên cứu của chúng tôi như sau: 1) Chúng tôi đề xuất một khung học tập bán giám sát mới có tên là Tự tiền đào tạo. Mô hình của chúng tôi dựa trên mô hình tự đào tạo, tuy nhiên, nó không có ngưỡng, nó có thể đối phó với vấn đề trôi dạt ngữ nghĩa và cũng có thể sửa đổi các tài liệu đã được gắn nhãn trước đó. Theo hiểu biết của chúng tôi,

Tự tiền đào tạo là mô hình đầu tiên giải quyết những nhược điểm này trong một khuôn khổ thống nhất.2)Chúng tôi đề xuất một lịch trình tốc độ học tập mới để tích hợp hiệu quả quy trình tối ưu hóa với quy trình học tập bán giám sát hai giai đoạn của chúng tôi.3)Để giảm thiểu hơn nữa vấn đề trôi dạt ngữ nghĩa, chúng tôi lập mô hình phân phối lớp của các nhãn giả như một quá trình ngẫu nhiên qua các lần lặp khởi động và đề xuất một cách tiếp cận mới để chuyển đổi các phân phối lớp.4)Chúng tôi thực hiện một bộ thử nghiệm toàn diện trên ba tập dữ liệu Twitter công khai và chứng minh rằng mô hình của chúng tôi hoạt động tốt hơn một số đường cơ sở hiện đại nhất trong nhiều cài đặt.

Nghiên cứu của chúng tôi rõ ràng đã thúc đẩy sự tiến bộ trong phân loại văn bản bán giám sát. Chúng tôi tin rằng các ý tưởng được trình bày trong bài báo của chúng tôi có thể được áp dụng cho các lĩnh vực khác, ví dụ: phân loại hình ảnh. Công việc trong tương lai có thể khám phá hướng này. Trong phần tiếp theo, chúng tôi cung cấp một cái nhìn tổng quan về các nghiên cứu liên quan và làm nổi bật các phẩm chất của Tự tiền đào tạo.

2 CÔNG VIỆC LIÊN QUAN

Dữ liệu chưa được gắn nhãn trong học tập bán giám sát. Dữ liệu không được gắn nhãn có thể được khai thác theo nhiều cách. Nó có thể được sử dụng như một siêu nguồn thông tin [21], nó có thể được sử dụng như một bộ điều chỉnh [56], hoặc nó có thể được sử dụng trong cài đặt điều chỉnh miền để tạo mối tương quan giữa nguồn và dữ liệu đích [51]. Mối quan tâm gần đây hơn đối với văn học là *tự giám sát*, trong đó một tác vụ khép kín được xác định sao cho không cần chú thích thủ công. Ví dụ của các nhiệm vụ như vậy là đào tạo trước mô hình ngôn ngữ [18, 41] trong NLP, và học tương phản trong xử lý hình ảnh [15, 46]. Từ một góc độ khác, các nghiên cứu tự giám sát có thể được phân loại thành các phương pháp tiếp cận theo nhiệm vụ [10] và theo nhiệm vụ cụ thể [22]. Điều này đã làm nảy sinh khái niệm về mô hình “prerain, sau đó là finetune”. Chúng tôi tích hợp mô hình này vào thuật toán tự đào tạo.

Khởi động trong học tập bán giám sát. Tự đào tạo là phương pháp học tập bán giám sát lâu đời nhất [14] ra đời từ năm 1965 [48]. Ý tưởng này tái xuất hiện trong công việc chính của Yarowsky [58] cho các nhiệm vụ NLP vào năm 1995, và một lần nữa trong cộng đồng thị giác máy tính vào năm 2013 như *dán nhãn giả* [33]. Thuật toán này là một trình bao bọc liên tục sử dụng một thuật toán được giám sát làm mô hình cơ bản. Có nhiều giả định trong đó việc tự đào tạo – và nói chung là học tập bán giám sát – được kỳ vọng sẽ hoạt động tốt. Ví dụ, *giả định êm ái* điều đó cho biết nếu hai điểm dữ liệu 1 và 2 gần, sau đó là dự đoán của họ 1 và 2 cũng nên gần - giả định này là cơ sở của các thuật toán như MixUp [60] và MixMatch [8]. Như chúng ta thảo luận trong phần tiếp theo, một khía cạnh không thỏa mãn của việc tự đào tạo là nó dựa vào các thuộc tính của mô hình dự đoán cơ bản, ví dụ, các phân phối đầu ra của mô hình. Đã có những nỗ lực để giải quyết nhược điểm này. Ví dụ, điều chỉnh [1] có thể được sử dụng để giảm bớt ảnh hưởng của các ứng viên ồn ào, hoặc trong bối cảnh học tập chuyển đổi, mật độ của các điểm dữ liệu không được gắn nhãn có thể được kết hợp để giảm thiểu vấn đề này [49].

Trong vài năm qua, các nghiên cứu đã khám phá hiệu quả của mạng nơ-ron như một mô hình dự đoán cơ bản trong quá trình tự đào tạo. Một biến thể mạng nơ-ron của đồng đào tạo [9] được đề xuất trong [42]. Trong [30], các tác giả đề xuất một khuôn khổ để tích hợp tri thức nhân loại với đồng đào tạo. Trong [55], một biến thể học tăng cường của đồng đào tạo được đề xuất. Trong [44], một biến thể mạng nơ-ron của

đào tạo tri với bất đồng [50] được trình bày, và cho thấy rằng sự kết hợp là một cơ sở mạnh mẽ đáng ngạc nhiên trong bối cảnh thích ứng miền. Các tác giả trong [13] đề xuất sử dụng điểm phân vị thay vì điểm tin cậy để chọn các nhãn giả tốt nhất; và các tác giả trong [39] sử dụng mạng nơ-ron Bayes để chọn các nhãn giả ít tin cậy nhất trong mỗi lần lặp lại. Trong [4], một chiến lược lấy mẫu tài liệu mới để tự đào tạo được đề xuất. Mô hình, ngoài độ tin cậy của trình phân loại, sử dụng các kỷ nguyên đào tạo trong đó các tài liệu không được gắn nhãn được gắn nhãn gần đúng. Trong [5], các tác giả đề xuất tích hợp MixUp [60] với việc lấy mẫu quá mức các ví dụ đào tạo được gắn nhãn. Họ cho thấy rằng tự đào tạo thực sự là một cơ sở rất tốt so với các kỹ thuật chính quy hóa và tăng cường dữ liệu thông thường. So với các nghiên cứu này, Tự thử nghiệm là mô hình đầu tiên sử dụng quá trình chưng cất mô hình [25] cùng với một giả thuyết để chuyển thông tin qua các lần lặp lại, cho phép nó có khả năng sửa đổi các nhãn giả. Nó tích hợp mô hình đào tạo trước / tinh chỉnh với tự đào tạo, sử dụng quy trình tối ưu hóa hiệu quả cùng với kỹ thuật nhiễu loạn để giảm thiểu tác động tiêu cực của các nhãn giả ồn ào.

Các nghiên cứu liên quan chặt chẽ khác. Ngoài các nghiên cứu trên, Self-Pretraining cũng liên quan đến các nghiên cứu về chưng cất mô hình [25] và tổ hợp thời gian [32]. Chưng cất mô hình đã được đề xuất trong [11, 25] để chuyển kiến thức từ mô hình này sang mô hình khác. Trong [16], các tác giả chỉ ra rằng việc chuyển giao kiến thức của một mạng lớn, được đào tạo bởi một nhiệm vụ tự giám sát, sang một mạng nhỏ cải thiện khả năng tổng quát hóa. Đóng góp chính của họ là cho thấy rằng các mô hình lớn được đào tạo dễ dàng hơn, và do đó, có thể được sử dụng như một proxy để đào tạo các mạng nhỏ. Mô hình của họ không lặp lại và không khám phá dữ liệu chưa được gắn nhãn để trích xuất thông tin mới. Các mạng tái sinh đã được đề xuất trong [19], các tác giả cho thấy rằng chỉ cần chưng cất một mạng nơ-ron vào chính nó sẽ cải thiện hiệu suất. Mô hình của họ không phải là một thuật toán bán giám sát và không được đề xuất để khai thác dữ liệu không được gắn nhãn. Các tác giả trong [57] chỉ ra rằng thuật toán tự huấn luyện thần kinh thường xuyên có thể được cải thiện bằng cách thêm nhiễu vào mô hình. Tương tự như công việc của chúng tôi, chúng tôi cho phép các nhãn giả phát triển qua các lần lặp lại. Ngoài bước này, họ không đề xuất bất kỳ sửa đổi nào đối với thuật toán tự đào tạo. Ngoài ra, hiệu quả của mô hình của họ không được khám phá trong bối cảnh bán giám sát. Một cách tiếp cận rất gần với nghiên cứu này được trình bày trong [23], nơi các tác giả một lần nữa chỉ ra rằng việc thêm nhiễu vào biểu diễn bên trong của mô hình sẽ nâng cao hiệu suất tự đào tạo. Dàn nhạc tạm thời đã được đề xuất trong [32]. Các tác giả đề xuất duy trì mức trung bình dự đoán trên mỗi mẫu của dữ liệu không được gắn nhãn trong các kỷ nguyên và hạn chế phương sai dự đoán. Mô hình của họ không dựa trên việc tự đào tạo, không có chiến lược để tách biệt dữ liệu được gắn nhãn khỏi dữ liệu không được gắn nhãn, và trở nên khó sử dụng khi sử dụng các tập dữ liệu lớn. Các tác giả trong [52] giải quyết độ phức tạp cao của việc tổng hợp theo thời gian bằng cách cập nhật trọng số của mô hình qua các kỷ nguyên, thay vì lưu trữ các dự đoán.

3 BÀI HỌC ĐƯỢC GIÁM SÁT BẬC NHẤT QUA TỰ PHÁT HIỆN

Chúng tôi bắt đầu phần này bằng cách cung cấp tổng quan về Tự đào tạo trước và nêu bật những điểm khác biệt của nó so với thuật toán tự đào tạo.

Sau đó, chúng tôi giới thiệu một loạt các chiến lược để khắc phục những nhược điểm của phương pháp tự sơ chế vani¹.

Trong thuật toán tự đào tạo [58], một tập hợp nhỏ các tài liệu được gắn nhãn và một tập hợp lớn các tài liệu không được gắn nhãn có sẵn để đào tạo. Thuật toán lặp đi lặp lại và trong mỗi lần lặp lại mô hình dự đoán được đào tạo trên bộ hiện tại và được sử dụng để gắn nhãn tập hợp hiện tại một cách xác suất. Đã đưa ra siêu tham số là ngưỡng tin cậy tối thiểu, các tài liệu được gắn nhãn tự tin nhất trong và liên kết của *họnhã giả* được chọn để được bổ sung với bộ. Quy trình này được lặp lại cho đến khi một tiêu chí nhất định được đáp ứng. Có ba nhược điểm với thuật toán này: 1) Vấn đề trôi dạt ngữ nghĩa [12], trong đó tác động tiêu cực ngày càng tăng của các nhãn giả nhiều làm lu mờ lợi ích của việc kết hợp dữ liệu không được gắn nhãn. 2) Phụ thuộc vào hiệu chuẩn mô hình. Nếu bộ phân loại bên dưới không thể lập mô hình chính xác các phân phối lớp, thì nó sẽ không thể xếp hạng đúng các tài liệu ứng viên, ví dụ, trong trường hợp mạng nơ-ron [35]. 3) Không thể sửa đổi các nhãn giả sau khi chúng được gán cho các tài liệu chưa được gắn nhãn và được bổ sung thêm với tập hợp các tài liệu được gắn nhãn. Mặc dù tồn tại các kỹ thuật để giải quyết những thách thức này trong một số điều kiện nhất định, ví dụ, điều chỉnh [1] để hiệu chuẩn mô hình kém hoặc khởi động độc quyền lẫn nhau [17] đối với sự trôi dạt ngữ nghĩa, theo hiểu biết của chúng tôi,

Thuật toán của chúng tôi là lặp đi lặp lại và sử dụng hai mạng nơ-ron làm bộ phân loại cơ bản. Thuật toán 1 minh họa quá trình tự đào tạo ở dạng cơ bản của nó. Ban đầu, bộ được sử dụng để đào tạo mạng 1 (Dòng 2), sau đó là các tham số của 1 được sao chép vào mạng 2 (Dòng 5). Trong bước tiếp theo, một tập hợp các tài liệu không được gắn nhãn được lấy ngẫu nhiên từ (Dòng 7). Tập hợp này được gắn nhãn bởi 2 và được sử dụng dọc theo bộ đào tạo lại 1 (Dòng 8). Vai trò của hai mạng được đảo ngược trong lần lặp tiếp theo. Trong mỗi lần lặp lại, kích thước mẫu được tăng lên (Dòng 6) và thuật toán dừng khi tập hợp mẫu bao gồm toàn bộ tập hợp. Cuối cùng, nhóm của 1 và 2 có thể được sử dụng để gắn nhãn các tài liệu không nhìn thấy – chúng tôi đã sử dụng giá trị trung bình của các dự đoán lớp của chúng.

Thuật toán 1 Tổng quan về Vanilla Self-Pretraining

```
1: hàm self_pretraining ( , )
2:   1 ← _ ( ) _ ← 0
3:   lặp lại
4:
5:     2 ← _ ( 1 ) _ ← _ +
6:
7:     ← _ ( , _ ) 1 ← _ (( , 2 )) ∪
số B:   } cho đến khi _ < | | trở về 1, 2
9:
10:
```

Thuật toán 1 có hai ưu điểm: 1) Để chọn các nhãn giả, phân phối lớp không được tính đến, do đó, không có ràng buộc về khả năng của bộ phân loại trong việc xếp hạng các tài liệu không được gắn nhãn. Ngoài ra, điều này ngăn không cho mô hình lặp lại

¹Chúng tôi tập trung vào các vấn đề phân loại nhị phân.
²Lưu ý rằng theo định nghĩa, quá trình tự đào tạo thần kinh yêu cầu khởi động lại và đào tạo lại trong mỗi lần lặp lại [44], do đó thuật toán của chúng tôi có thể so sánh với các mô hình tự đào tạo khác về thời gian chạy.

chọn một tập hợp cố định gồm các tài liệu không được gắn nhãn trong mỗi lần lặp lại — tức là, tập hợp các nhãn giả có độ tin cậy cao. 2) Thông tin được chuyển qua các lần lặp ở dạng giả thuyết hơn là một tập hợp các nhãn giả cố định. Do đó, niềm tin của mô hình về các nhãn giả có thể phát triển theo thời gian – các nhãn giả không được tăng cường với tập hợp các tài liệu được gắn nhãn. Mặt khác, thuật toán này có một nhược điểm đáng kể, và đó là vấn đề trôi dạt ngữ nghĩa. Trên thực tế, việc lấy mẫu ngẫu nhiên từ tập hợp các tài liệu không có nhãn sẽ làm trầm trọng thêm vấn đề này bằng cách đưa vào các nhãn nhiễu và đẩy giả thuyết đã chuyển về phía điểm tối ưu. Trong những điều sau đây,

3.1 Chuyển giao giả thuyết và chưng cất lặp đi lặp lại

Tự luyện tiền thử chuyển một giả thuyết – một hàm đã học – từ lần lặp này sang lần lặp tiếp theo. Trong mỗi lần lặp lại, giả thuyết này được sử dụng để tạo một giả thuyết mới bằng cách tạo một tập hợp các nhãn giả và bổ sung chúng với tập hợp các tài liệu được gắn nhãn. Mặc dù tiêu chí cuối cùng là tối đa hóa tiện ích của mô hình, nhưng mục tiêu ngắn hạn trong mỗi lần lặp lại không nhất thiết phải đưa ra dự đoán chính xác mà là chuyển giao kiến thức một cách cẩn thận từ mô hình này sang mô hình khác. Hai quy trình này không nhất thiết phải phù hợp với nhau, vì quy trình trước có thể dựa vào kết quả của người học và quy trình sau có thể dựa vào chính quy trình học tập. Do đó, các nhãn của bộ phân loại, mặc dù có nhiều thông tin, nhưng không đủ biểu đạt để chuyển toàn bộ kiến thức từ lần lặp này sang lần lặp tiếp theo.

Các tác giả trong [11, 25] đề xuất một thuật toán gọi là chưng cất mô hình để chuyển kiến thức từ một mô hình lớn (được gọi là *cô giáo*) sang một mô hình nhỏ (được gọi là *sinh viên*). Việc chắt lọc mô hình dựa trên lập luận rằng phân phối lớp mang một lượng thông tin đáng kể liên quan đến ranh giới quyết định của bộ phân loại. Ví dụ, cho một tài liệu được gắn nhãn tích cực, sẽ không phải là thông tin quan trọng khi biết rằng nếu dự đoán của lớp là 95% tích cực hoặc 65% tích cực. Các tác giả trong [25] sử dụng phương pháp chưng cất mô hình để chuyển kiến thức từ mạng này sang mạng khác bằng cách sửa đổi lớp softmax như sau:

$$= \sum \frac{\exp-}{\exp-} \tag{1}$$

ở đây là lớp cuối cùng *i*-thăng nhập, là số lớp, và là dự đoán của lớp. Siêu tham số được gọi là nhiệt độ và được sử dụng để làm trơn các dự đoán của lớp. Nhiệt độ cao hơn dẫn đến entropy cao hơn trong các dự đoán. Điều này đặc biệt mong muốn, vì mạng nơ-ron được biết là có entropy thấp trong các dự đoán của chúng [35].

Với lập luận ở trên, chúng tôi sử dụng quá trình chắt lọc mô hình trong Tự luyện tiền thử nghiệm và chắt lọc hiệu quả các lần lặp trước đó vào mạng sinh viên 1. Do đó, trong mỗi lần lặp, thay vì sử dụng giáo viên – Các dự đoán cứng trên các tài liệu không được gắn nhãn, chúng tôi sử dụng các dự đoán mềm cùng với tập hợp để đào tạo mạng sinh viên – Thuật toán 1, Dòng 8.

3.2 Học tập bán giám sát hai giai đoạn

Như chúng tôi đã đề cập trước đó, tự đào tạo gặp phải vấn đề trôi dạt ngữ nghĩa. Sự cố này xảy ra khi các lỗi chủ yếu do nhãn giả gây ra tích tụ qua các lần lặp lại và cuối cùng làm sai lệch ranh giới của bộ phân loại. Mặc dù ngưỡng tin cậy tối thiểu có khả năng ngăn chặn các nhãn giả xâm nhập vào tập huấn luyện, như tập hợp tăng kích thước thì xác suất ghi nhãn sai các tài liệu sẽ tăng lên tương ứng. Vấn đề này thậm chí còn nghiêm trọng hơn trong mô hình của chúng tôi, vì nó không có ngưỡng. Một giải pháp đơn giản là gán trọng số thấp hơn cho các nhãn giả, tuy nhiên, chúng tôi nhận thấy trong các thí nghiệm của mình rằng cách tiếp cận này không đủ hiệu quả để giải quyết vấn đề cơ bản.

Để giảm thiểu vấn đề này, một giải pháp là xử lý tập hợp các nhãn giả và tách thông tin mâu thuẫn với thông tin được lưu trữ trong tập hợp. Xóa phần này của các nhãn giả có thể giảm tỷ lệ lỗi và sau đó cải thiện giả thuyết trong lần lặp hiện tại. Để thực hiện điều này, chúng tôi khai thác hiện tượng quên thảm khốc trong mạng nơ-ron [31, 36]. Sự quên nghiêm trọng xảy ra trong cài đặt học tập liên tục, nơi mạng được đào tạo về một loạt nhiệm vụ. Mỗi quy trình đào tạo cập nhật các tham số của mô hình để đáp ứng các yêu cầu của hàm mục tiêu, và các cập nhật trong tác vụ hiện tại có thể mâu thuẫn và xóa thông tin liên quan đến các tác vụ trước đó. Hiệu ứng này thường là không mong muốn, tuy nhiên, trong bối cảnh Tự thử nghiệm, chúng tôi sử dụng cơ chế này như một proxy để xây dựng hệ thống phân cấp thông tin trong mạng. Do đó, chúng tôi thực hiện một sửa đổi nhỏ trong Thuật toán 1. 1, và sau đó đào tạo thêm bằng cách sử dụng tập hợp các tài liệu được gắn nhãn.

Việc chia nhỏ quy trình đào tạo thành hai giai đoạn đưa ra một thách thức mới và đó là khả năng cập nhật hoàn toàn các thông số mạng để tìm hiểu các quy định trong tập hợp các tài liệu được gắn nhãn. Để tránh điều này, chúng tôi đề xuất sử dụng hàm mục tiêu sau trong khi đào tạo mô hình sử dụng bộ :

$$L = (1 - \sum_{i=1}^n [\text{khúc gỗ} + (1 -) \log(1 -)]) + \sum_{i=1}^n [- (\text{khúc gỗ} + (1 -) \log(1 -))] \quad (2)$$

ở đây là số lượng tài liệu trong bộ , là nhãn thực của tài liệu , là dự đoán lớp của 1_{vi} , là dự đoán lớp của 1_{vi} với nhiệt độ cao như được mô tả trong Phần 3.1, và là dự đoán lớp của 2_{vi} với nhiệt độ tương tự như nhiệt độ của 1_{vi} là một siêu tham số để chi phối trọng số tương đối của hai số hạng ($0 \leq \leq 1$). Từ các bậc của số hạng thứ hai trong Phương trình 2 chia tỷ lệ bằng $\frac{1}{2}$, theo thứ tự để cân bằng tác động của hai thuật ngữ trong lan truyền ngược, chúng tôi nhân các độ dốc này với 2-Xem phương trình 1.

Số hạng đầu tiên trong Công thức 2 là entropy chéo giữa các nhãn chân trị cơ bản và xác suất lớp của 1. Số hạng thứ hai là entropy chéo giữa các xác suất lớp của 2_{vi} và 1. Chức năng mục tiêu này là một nỗ lực để giữ cân bằng giữa thông tin được chuyển từ các lần lặp trước và thông tin được trích xuất từ tập hợp các tài liệu được dán nhãn .

Trong Phần 5, chúng tôi chứng minh rằng các ý tưởng được đề xuất trong phần này sẽ gắn kết đáng kể khả năng chống lại tiếng ồn của các nhãn giả. Những ý tưởng này có liên quan đến hai loại nghiên cứu: 1) Các nghiên cứu về mạng nơ-ron tiền huấn luyện [24, 27]. 2) Các nghiên cứu về học theo chương trình [7]. Các nhà nghiên cứu [24, 27] trong cả NLP và cộng đồng thị giác đã chỉ ra rằng *tập huấn trước* một mạng nơ-ron với dữ liệu ngoài miền và sau đó *điều chỉnh* nó với dữ liệu mục tiêu có thể đóng góp đáng kể vào hiệu suất. Hai bước này tương tự như hai giai đoạn mà chúng tôi đã mô tả trong phần này. Ngoài ra, công việc của chúng tôi cũng liên quan chặt chẽ đến ý tưởng về việc học theo chương trình [7], nơi cho thấy rằng người học có thể tận dụng thứ tự của các ví dụ đào tạo để học hiệu quả hơn. Mặc dù Tự tiền thử nghiệm sử dụng cơ chế này, tiêu chí để xác định thứ tự của các ví dụ đào tạo không dựa trên các thuộc tính của điểm dữ liệu mà dựa trên nguồn của nhãn.

3.3 Tỷ lệ học tập Hình thang phải

Trong phần trước, chúng tôi đã sử dụng một cách tiếp cận để giảm thiểu vấn đề trôi dạt ngữ nghĩa bằng cách khai thác hiện tượng quên thảm khốc. Chiến lược hai giai đoạn này tạo ra một cơ hội thích hợp để nâng cao quá trình tối ưu hóa. Vì các nhãn giả có khả năng bị nhiễu, chúng tôi đề xuất sử dụng tập hợp này để khám phá không gian giả thuyết và phát hiện vùng có chứa localoptima tốt hơn. Sau đó, tập hợp các tài liệu được gắn nhãn, không có tiếng ồn, có thể được sử dụng để phát hiện mục tiêu tối ưu cục bộ.

Với lập luận ở trên, chúng tôi đề xuất sử dụng *hình thang bên phải* tỷ lệ học tập – minh họa {d trong Hình 1 – như sau:


$$l = \frac{hC}{C} \quad h < h$$

ở đây biểu thị bước thời gian hiện tại và h là lô tài liệu hiện tại đang được xử lý. l là tỷ lệ học tập hiện tại, là tỷ lệ học tập ban đầu, là tập hợp các nhãn giả, là tập hợp các tài liệu được dán nhãn, là số lô nhãn giả và là số lô được dán nhãn.

Tỷ lệ học tập được đề xuất của chúng tôi bao gồm hai giai đoạn: 1) Tỷ lệ học tập cố định – đường gạch ngang trong Hình 1 – nơi giả nhãn được sử dụng để đào tạo mô hình 1-See Thuật toán 1. Trong giai đoạn này, các tham số mạng có thể tự do cập nhật, và do đó, người học về cơ bản có thể khám phá không gian giả thuyết. 2) Tốc độ học tập giảm dần - đường nghiêng liền nét trong Hình 1 - nơi các tài liệu được gắn nhãn được sử dụng để đào tạo thêm mạng. Trong giai đoạn này, trình tối ưu hóa ổn định, do đó, chúng tôi sử dụng các tài liệu được dán nhãn không gây tiếng ồn, vì ngay cả một sự xáo trộn nhỏ trong dữ liệu cũng có thể gây ra mất mát đáng kể. Có tỷ lệ học tập hai giai đoạn cũng tích hợp hữu cơ với quy trình học tập bán giám sát hai giai đoạn của chúng tôi. Vì tốc độ học giảm dần, ngăn mục tiêu của nhiệm vụ thứ hai xóa hoàn toàn kiến thức đã chuyển từ các lần lặp trước.

3.4 Phân phối theo lớp quán tính

Mô hình học tập bán giám sát dựa trên dữ liệu không được gắn nhãn làm nguồn thông tin chính của chúng. Mặc dù các phương pháp này đã thu được những kết quả đầy hứa hẹn, nhưng chúng vốn dĩ có xu hướng được trang bị quá mức đối với những điểm bất thường trong dữ liệu không được gắn nhãn. Giới thiệu một khuyến khích quy nạp [38] vào các thuật toán học bán giám sát là một điều phổ biến



Hình 1: Lịch trình tỷ lệ học tập Tự thử nghiệm. Đường gạch ngang là tốc độ học của mạng trong quá trình đào tạo theo nhãn giả và đường nghiêng là tốc độ học trong quá trình đào tạo bởi các tài liệu được gắn nhãn.

cách tiếp cận để tăng cường độ mạnh mẽ của chúng. Ví dụ: chính quy hóa theo hệ mét [47] hoặc tập hợp theo thời gian [32] là một vài ví dụ. Trong khi các kỹ thuật này có thể được tích hợp vào Tự tiền thử nghiệm, trong phần này, chúng tôi chọn khám phá một hướng mới.

Chúng tôi giả thuyết rằng phân phối xác suất lớp của tập hợp các tài liệu không gắn nhãn được chọn ngẫu nhiên – Thuật toán 1, Dòng 8– sẽ phát triển chậm và tránh chuyển đổi đột ngột qua các lần lặp lại. Đây là một giả định khắc nghiệt, vì phân phối xác suất này cũng phụ thuộc vào các mẫu được rút ra. Tuy nhiên, chúng tôi tranh luận rằng sự thay đổi đột ngột trong phân phối này có thể là dấu hiệu của một loạt các nhãn giả ồn ào trong các lần lặp trước. Vì vậy, chúng tôi hướng tới việc cấm những thay đổi như vậy. Để đạt được điều này, chúng tôi giả định phân phối xác suất lớp là một quá trình ngẫu nhiên phát triển động qua các lần lặp và phân phối xác suất lớp của các tài liệu không được gắn nhãn đã chọn trong mỗi lần lặp– 2() trong Thuật toán 1 – là một mẫu từ các biến ngẫu nhiên cơ bản.

Để đơn giản, chúng tôi giả sử quá trình chỉ bao gồm một họ hai biến ngẫu nhiên Gaussian +và -, ở đâu +là trạng thái của các nhãn giả tích cực và -là trạng thái của các nhãn giả âm. Giá trị trung bình mẫu và phương sai của +trong sự lặp lại (I E, +) được đưa ra bởi:

$$\begin{aligned} \bar{x} &= \frac{\sum_{i=1}^n x_i}{n} \\ \sigma^2 &= \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \end{aligned}$$

ở đâu là số lượng nhãn giả dương trong lần lặp lại , và là xác suất của i -th thuộc về nhãn giả tích cực vào lớp tích cực – rõ ràng là $0.5 \leq \bar{x} \leq 1$, bởi vì mẫu là tích cực. Tương ứng, giá trị trung bình mẫu và phương sai của -trong sự lặp lại (I E, -) được đưa ra bởi:

$$\begin{aligned} \bar{y} &= \frac{\sum_{i=1}^n y_i}{n} \\ \sigma^2 &= \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1} \end{aligned}$$

ở đâu là số lượng nhãn giả phủ định trong lần lặp lại , và là xác suất của i -th thuộc về nhãn giả phủ định cho lớp phủ định – lưu ý rằng $0.5 \leq \bar{y} \leq 1$ và cũng lưu ý rằng đối với mọi nhãn giả $+ + = 1$.

Trong sự lặp lại +1, các phân phối mẫu của ngẫu nhiên biến +và -tiến hành + $+1 \sim N(\bar{x} + 1, \sigma^2 + 1)$ và - $+1 \sim N(\bar{y} + 1, \sigma^2 + 1)$. Những cập nhật này có thể là do sự ngẫu nhiên trong

Dataset	Tập huấn			Thử nghiệm		
	Tweets	Người da đen	Vị trí	Tweets	Người da đen	Vị trí
ADR	20624	91%	9%	4992	92%	số 8%
Động đất	8166	53%	47%	3502	53%	47%
Sản phẩm	4503	69%	31%	2114	78%	22%

Bảng 1: Tóm tắt bộ dữ liệu ADR, Động đất và Sản phẩm.

khởi tạo mô hình, tính ngẫu nhiên trong tập hợp các tài liệu không được gắn nhãn đã chọn trong lần lặp , hoặc một phần do các nhãn giả ồn ào được giới thiệu trong lần lặp lại . Cụ thể hơn, sự phân loại sai của mô hình 2 trong sự lặp lại – Xem Thuật toán 1 – sau đó được sử dụng để đào tạo trước mô hình 1, và cuối cùng làm sai lệch phân phối lớp của tập hợp các nhãn giả trong lần lặp +1. Để giảm bớt tác động của tiếng ồn này, chúng tôi xác định hai phân phối Gaussian + +1và - +1 như sự kết hợp tuyến tính của các phân phối lớp trong các lần lặp lại và +1 và dự án 3 các nhãn giả trong +1 vào trong +1 và các nhãn giả trong - +1

vào trong +1. Như vậy:

$$\begin{aligned} \bar{x}_{+1} &= \bar{x} + (1 - \bar{x}) + 1 \\ \sigma_{+1}^2 &= \sigma^2 + (1 - \sigma^2) + 1 \end{aligned} \quad (3)$$

ở đâu là một siêu tham số để chi phối tốc độ mà phân phối xác suất có thể phát triển trong mỗi lần lặp lại. Bản phân phối mới-butions +1và +1 được xác định giữa các phân phối lớp trong sự lặp lại và +1. Siêu tham số xác định mức độ mà các nhãn giả trong lần lặp lại +1 bị xáo trộn để giống với các nhãn giả trong lần lặp lại . Bằng cách sử dụng cơ chế này, sẽ tránh được những thay đổi đột ngột trong việc phân phối nhãn giả. Chúng tôi thực hiện bước này sau khi chúng tôi tạo các nhãn giả bằng mô hình 2 và trước khi sử dụng bộ này để đào tạo trước mô hình 1– Thuật toán 1, dòng 8.

Trong Phần 5, chúng tôi chỉ ra rằng thuật toán Tự tiền thử nghiệm, cùng với các kỹ thuật mà chúng tôi đã giới thiệu trong các phần 3.1, 3.2, 3.3 và 3.4 đạt được kết quả hiện đại trong nhiều cài đặt. Trong phần tiếp theo, chúng tôi mô tả tập dữ liệu, đường cơ sở và thiết lập đào tạo của chúng tôi.

4 THIẾT LẬP THỰC NGHIỆM

Chúng tôi bắt đầu phần này bằng cách mô tả các tập dữ liệu mà chúng tôi đã sử dụng, sau đó chúng tôi cung cấp tổng quan ngắn gọn về các mô hình cơ sở và cuối cùng là xem xét chi tiết các thử nghiệm.

4.1 Bộ dữ liệu

Chúng tôi đánh giá quá trình tự tiền đào tạo trên ba nhiệm vụ phân loại văn bản Twitter: 1) Giám sát phản ứng có hại của thuốc (ADR). Trong nhiệm vụ này, mục tiêu là phát hiện các tweet thông báo về tác dụng phụ của thuốc. Chúng tôi đã sử dụng tập dữ liệu được giới thiệu trong [53] được chuẩn bị cho Nhiệm vụ được chia sẻ SMM4H của ACL 2019. 2) Phát hiện Báo cáo Khủng hoảng (CRD). Trong nhiệm vụ này, mục tiêu là phát hiện các tweet đề cập đến một sự kiện liên quan đến thiên tai. Chúng tôi đã sử dụng tập dữ liệu được giới thiệu trong [2] về trận động đất ở Nepal năm 2015. 3) Nhận dạng Mẫu Tiêu thụ Sản phẩm (PCP). Trong nhiệm vụ này, mục tiêu là xác định các tweet báo cáo việc sử dụng sản phẩm. Chúng tôi đã sử dụng tập dữ liệu được giới thiệu trong [28], tập dữ liệu này nói về việc tiêm vắc-xin cúm.

³Không có phép chiếu nào được thực hiện trong lần lặp đầu tiên.

⁴Vui lòng tham khảo các bài báo đã trích dẫn để phân tích và thảo luận về những khó khăn của các nhiệm vụ này, chúng tôi bỏ qua chủ đề này.

Bộ dữ liệu ADR và Động đất được phát hành cùng với các bộ thử nghiệm và đào tạo được chỉ định trước. Trong Tập dữ liệu sản phẩm, chúng tôi sử dụng các tweet được xuất bản vào năm 2013 và 2014 cho tập huấn luyện và các tweet được xuất bản vào năm 2015 và 2016 cho tập thử nghiệm. Bảng 1 tóm tắt các bộ dữ liệu. Chúng tôi thấy rằng tập dữ liệu Động đất là cân bằng và tập dữ liệu ADR rất mất cân bằng. Tập dữ liệu về Động đất được phát hành cùng với một tập hợp các tweet không được gắn nhãn. Đối với hai tập dữ liệu còn lại, chúng tôi đã sử dụng API Twitter và thu thập dữ liệu 10.000 tweet có liên quan cho mỗi tập dữ liệu được sử dụng làm tập hợp không được gắn nhãn (tập trong Thuật toán 1). Đối với tập dữ liệu ADR, chúng tôi đã sử dụng tên thuốc để thu thập tập hợp không được dán nhãn và đối với tập dữ liệu Sản phẩm, chúng tôi sử dụng truy vấn “cúm V&A (vắc xin tiêm ngừa HO&A)” để thu thập tập hợp.

4.2 Đường cơ sở

Chúng tôi so sánh mô hình của chúng tôi với sáu đường cơ sở.

*Đường cơ sở.*Thiết lập để đánh giá mô hình học tập bán giám sát phải thực tế. Các mô hình ngôn ngữ theo ngữ cảnh định sẵn là thành phần chính của bộ phân loại văn bản hiện đại. Do đó, chúng tôi đã sử dụng BERT [18] làm đường cơ sở ngây thơ và cũng là bộ phân loại cơ bản cho tất cả các đường cơ sở khác. Lưu ý rằng điều này làm cho bất kỳ cải tiến nào đối với bộ phân loại cơ sở là rất khó khăn, vì cải tiến này phải là tính năng bổ sung. Chúng tôi đào tạo mô hình này trên tập hợp các tài liệu được gắn nhãn và đánh giá trên tập thử nghiệm. Chúng tôi đã sử dụng tài liệu đào tạo trước đã xuất bản*căn cứ* biến thể, tiếp theo là một lớp được kết nối đầy đủ và một lớp softmax. Chúng tôi đã sử dụng triển khai Pytorch [54] của BERT; cài đặt giống với các đề xuất trong [18]. *Tự đào tạo.*Chúng tôi đã bao gồm thuật toán tự đào tạo thông thường [58], trong đó trong mỗi lần lặp lại, các nhãn giả hàng đầu, tuân theo độ tin cậy ngưỡng tối thiểu, được chọn và thêm vào tập hợp được gắn nhãn. Chúng tôi đã sử dụng một phiên bản của*Đường cơ sở*trong thuật toán này. *Tri-training* +.Chúng tôi đã đưa vào một biến thể của thuật toán đào tạo ba lần được gọi là đào tạo ba với sự bất đồng [50]. Trong [44], các tác giả chỉ ra rằng mô hình này là cơ sở rất tốt cho việc học bán giám sát. Chúng tôi đã sử dụng ba trường hợp của*Đường cơ sở*trong thuật toán này. *Học hỏi lẫn nhau.*Chúng tôi bao gồm mô hình được giới thiệu trong [61]. Mô hình này là một tập hợp, và dựa trên ý tưởng rằng việc tăng entropy của các dự đoán lớp sẽ cải thiện tính tổng quát hóa [40]. Chúng tôi đã sử dụng hai trường hợp của*Đường cơ sở*trong mô hình này – trong cài đặt song song. *Khoảng cách đại diện.*Chúng tôi bao gồm mô hình được giới thiệu trong [4]. Mô hình này sử dụng kỹ thuật xếp hàng dọc theo tập hợp xác thực để chọn các tài liệu không được gắn nhãn dễ dàng và cũng đầy đủ thông tin cho nhiệm vụ. Chúng tôi đã sử dụng cách triển khai mô hình này của riêng mình. *Đồng phân rã.*Chúng tôi đã bao gồm khuôn khổ được giới thiệu trong [30]. Mô hình này sử dụng kiến trúc miền để phân tách nhiệm vụ thành một tập hợp các nhiệm vụ con cần giải quyết trong cài đặt nhiều chế độ xem. Chúng tôi đã sử dụng đại diện cấp độ từ khóa và biểu thị cấp độ câu làm hai chế độ xem. Chúng tôi đã sử dụng hai trường hợp của*Đường cơ sở*trong thuật toán này. *Tự tiền đào tạo.*Mô hình mà chúng tôi đã giới thiệu trong Phần 3. Chúng tôi đã sử dụng hai phiên bản của*Đường cơ sở*như 1và 2.

4.3 Chi tiết thử nghiệm

Để đánh giá các mô hình trong cài đặt bán giám sát, chúng tôi đã lấy mẫu một tập hợp con nhỏ các nhóm đào tạovà không sử dụng phần còn lại của các tweet. Lưu ý rằng tập hợp còn lại cũng không được sử dụng làm dữ liệu chưa được gắn nhãn – xem Phần 4.1 để biết mô tả về nhóm chưa được gắn nhãn

^sViệc sử dụng toàn bộ tập hợp các tweet được gắn nhãn biến nhiệm vụ phân loại thành một vấn đề được giám sát, đây không phải là chủ đề nghiên cứu của chúng tôi.

các bộ. Để lấy mẫu dữ liệu, chúng tôi sử dụng phương pháp lấy mẫu ngẫu nhiên phân tầng để bảo toàn tỷ lệ giữa tài liệu dương và tài liệu âm. Chúng tôi cũng đảm bảo rằng tập hợp có nhãn ban đầu là giống hệt nhau cho tất cả các mô hình. Chúng tôi lặp lại tất cả các thí nghiệm 3 lần với các hạt ngẫu nhiên khác nhau. Chúng tôi sẽ báo cáo mức trung bình qua các lần chạy. Tất cả các mô hình cơ sở sử dụng điều chỉnh [1] với ngưỡng tin cậy ($\text{l}=0.9$). Tuy nhiên, chúng tôi cũng tăng tuyến tính kích thước của tập mẫu [45], không thêm quá 10% tập huấn luyện hiện tại trong mỗi lần lặp.

Trong các thử nghiệm của mình, chúng tôi quan sát thấy rằng hiệu suất của *tự đào tạo*và*Co-Decomp*suy giảm nếu chúng ta sử dụng toàn bộ tập dữ liệu không được gắn nhãn – do vấn đề trôi dạt ngữ nghĩa. Do đó, chúng tôi giả định số lần lặp lại trong các thuật toán này là một siêu tham số và sử dụng 20% tập hợp được gắn nhãn làm tập xác nhận để tìm giá trị tốt nhất. *Tri-training* +có tiêu chí dừng nội bộ.*Học hỏi lẫn nhau*sử dụng dữ liệu chưa được gắn nhãn làm bộ điều chỉnh.*Spaced-rep*yêu cầu một bộ xác nhận cho tiêu chí dừng và cả cho việc lựa chọn ứng viên. Do đó, trong mô hình này, chúng tôi đã sử dụng 20% tập hợp được gắn nhãn làm tập xác nhận. Chúng tôi cũng đặt số lượng hàng đợi là 6, phần còn lại của cài đặt giống hệt với những gì được sử dụng trong [4].

Vì chúng tôi đang thử nghiệm trong cài đặt bán giám sát, chúng tôi đã không thực hiện điều chỉnh siêu tham số đầy đủ. Chúng tôi đã sử dụng tập hợp đào tạo trong Tập dữ liệu sản phẩm và tìm kiếm các giá trị tối ưu của_ trong phương trình 2 và trong phương trình 3. Giá trị tốt nhất của chúng lần lượt là 0,3 và 0,1. Chúng tôi đặt kích thước bước trong Thuật toán 1 đến 2.000 và nhiệt độ trong Phương trình 1 đến 3. Trong quy trình đào tạo hai giai đoạn của chúng tôi, mục tiêu của bước đầu tiên là khởi tạo mô hình, do đó chúng tôi đã đào tạo mạng chỉ trong 1 kỷ nguyên. Trong các trường hợp còn lại, bao gồm cả trong mô hình của chúng tôi và các đường cơ sở, chúng tôi đã đào tạo các mô hình trong 3 kỷ nguyên. Ngoại lệ duy nhất là*Space-đại diện*, đòi hỏi một số kỷ nguyên đào tạo nhất định với việc dừng lại sớm. Để huấn luyện BERT trong tất cả các trường hợp, chúng tôi đã sử dụng cài đặt giống với cài đặt của tham chiếu [18] –chúng tôi đặt kích thước lô thành 32. Tiếp theo đối số trong [37], chúng tôi sử dụng F1 trong lớp tích cực để điều chỉnh các mô hình. Trong phần tiếp theo, chúng tôi báo cáo F1, Độ chính xác và Thu hồi trung bình của các mô hình trong các lần chạy.

5 KẾT QUẢ VÀ THẢO LUẬN

Chúng tôi bắt đầu phần này bằng cách báo cáo kết quả chính. Sau đó, chúng tôi trình bày một loạt các thí nghiệm mà chúng tôi đã thực hiện để hiểu rõ hơn về các tính chất của Tự tiền luyện.

5.1 Kết quả chính

Bảng 2 báo cáo hiệu suất của Tự thử nghiệm so với đường cơ sở dưới hai lượng lấy mẫu - tức là 300 và 500 tweet ngẫu nhiên ban đầu - trong ba tập dữ liệu. Chúng tôi thấy rằng trong tất cả các trường hợp, Tự tiền đào tạo là mô hình hàng đầu hoặc ngang hàng với mô hình hàng đầu. Tuy nhiên, sự khác biệt trong tập dữ liệu ADR là đáng kể, trong tập dữ liệu Earthquake, sự khác biệt là rất nhỏ. ADR là một tập dữ liệu không cân bằng. Kiểm tra theo từng trường hợp của chúng tôi cũng cho thấy rằng các tweet tích cực trong tập dữ liệu này rất đa dạng, điều này làm cho các mô hình rất dễ bị ảnh hưởng bởi số lượng các ví dụ đào tạo. Chúng tôi cũng thấy rằng*Học hỏi lẫn nhau*hoàn toàn không thành công trong tập dữ liệu này. Các thử nghiệm của chúng tôi cho thấy rằng điều này là do phân phối lớp bị lệch trong tập dữ liệu này6. Thật ngạc nhiên, chúng tôi thấy rằng*Spaced-rep*đang hoạt động kém trong các thử nghiệm, mặc dù trước đó mô hình này đã được đánh giá trên các nhiệm vụ truyền thông xã hội [4]. Chúng tôi tin rằng lý do

⁶Chúng tôi đã xây dựng hai tập dữ liệu không cân bằng bằng cách lấy mẫu con từ tập dữ liệu Earthquake và Product, mô hình này cũng không thành công trong những trường hợp này.

# Tweets	Mô hình	Tập dữ liệu ADR			Bộ dữ liệu động đất			Bộ dữ liệu sản phẩm		
		F1	Độ chính xác	Nhớ lại	F1	Độ chính xác	Nhớ lại	F1	Độ chính xác	Nhớ lại
300	<i>Đường cơ sở</i>	0,238	0,237	0,342	0,715	0,692	0,749	0,728	0,696	0,770
	<i>Tự đào tạo</i>	0,303	0,269	0,350	0,728	0,697	0,762	0,731	0,675	0,798
	<i>Tri-training +</i>	0,306	0,236	0,448	0,735	0,680	0,799	0,734	0,659	0,828
	<i>Học hỏi lẫn nhau</i>	0,024	0,707	0,012	0,743	0,685	0,814	0,753	0,778	0,730
	<i>Spaced-rep</i>	0,258	0,248	0,277	0,721	0,650	0,811	0,727	0,701	0,760
	<i>Co-Decomp</i>	0,310	0,288	0,356	0,728	0,722	0,735	0,754	0,756	0,758
	<i>Tự tiền đào tạo</i>	0,397	0,370	0,440	0,737	0,704	0,772	0,766	0,757	0,777
500	<i>Đường cơ sở</i>	0,312	0,253	0,411	0,746	0,735	0,760	0,740	0,704	0,782
	<i>Tự đào tạo</i>	0,335	0,300	0,387	0,737	0,765	0,714	0,741	0,739	0,745
	<i>Tri-training +</i>	0,365	0,298	0,480	0,747	0,707	0,793	0,758	0,697	0,833
	<i>Học hỏi lẫn nhau</i>	0,108	0,638	0,059	0,751	0,730	0,773	0,767	0,811	0,728
	<i>Spaced-rep</i>	0,295	0,274	0,417	0,728	0,694	0,775	0,737	0,693	0,788
	<i>Co-Decomp</i>	0,345	0,313	0,388	0,749	0,746	0,752	0,766	0,771	0,764
	<i>Tự tiền đào tạo</i>	0,420	0,376	0,483	0,752	0,718	0,789	0,787	0,784	0,792

Bảng 2: F1, độ chính xác và thu hồi của Tự thử nghiệm trong bộ dữ liệu ADR, Động đất và Sản phẩm so với các mô hình cơ sở. Các mô hình đã được đào tạo trên 300 và 500 bài đăng của người dùng được dán nhãn.


k	F1	Độ chính xác	Nhớ lại
1000	0,395	0,306	0,565
2000	0,420	0,376	0,483
3000	0,428	0,386	0,485
4000	0,413	0,347	0,537

Bảng 3: Kết quả của quá trình tự tiền đào tạo với các giá trị khác nhau của k – số lượng nhãn giả được chọn ngẫu nhiên – trong bộ dữ liệu ADR thử nghiệm. Các mô hình bắt đầu với 500 bài đăng của người dùng được dán nhãn.

như sau: Mô hình này dựa vào số lượng ký nguyên đào tạo để xây dựng cấu trúc dữ liệu nội bộ của nó nhằm xếp hạng các tweet ứng viên. Khi trình phân loại cơ bản là một mô hình ngôn ngữ được đào tạo trước, ví dụ: bert, việc tăng số lượng ký nguyên có thể dẫn đến trang bị quá mức và do đó, mâu thuẫn với mục đích. Mặt khác, việc dừng sớm cũng ngăn mô hình phân tách thông tin từ các tweet không có thông tin.

5.2 Phân tích thực nghiệm

Chúng tôi bắt đầu phần này bằng cách báo cáo ảnh hưởng của kích thước bước về Thuật toán Tự thử nghiệm –see 1. Bảng 3 báo cáo F1, độ chính xác và thu hồi của Tự thử nghiệm ở các kích thước bước khác nhau trong tập thử nghiệm của bộ dữ liệu ADR. Vì bộ dataset này là bộ lớn nhất, chúng tôi báo cáo tất cả các thử nghiệm trong bộ dữ liệu này. Chúng tôi thấy rằng hiệu suất được cải thiện lên đến kích thước bước của 3000 tweet không được gắn nhãn mỗi lần lặp. Chúng tôi vẫn chưa có lời giải thích cụ thể để biện minh cho xu hướng này, vì điều tự nhiên là mong đợi kích thước bước nhỏ hơn sẽ mang lại kết quả tốt hơn. Một lý do có thể là nếu tập hợp các nhãn giả nhỏ, mạng hoàn toàn có thể học được nhiều trong tập hợp đó trong quá trình đào tạo trước. Trong Phần 3.2, chúng tôi lập luận rằng đào tạo hai giai đoạn có thể đối phó với vấn đề trôi dạt ngữ nghĩa. Để hỗ trợ đối số này, chúng tôi báo cáo hiệu suất của bộ phân loại trung gian 1 vào cuối mỗi lần lặp. Hình 2 báo cáo các hoạt động trong quá trình đào tạo cho các kích thước bước khác nhau. Chúng tôi thấy rằng đối với không có kích thước bước nào, hiệu suất giảm khi số lượng tweet không được gắn nhãn tăng lên – triệu chứng điển hình của trôi dạt ngữ nghĩa.



Hình 2: F1 của bộ phân loại kết quả trong mỗi lần lặp lại của Tự tiền thử nghiệm với các giá trị khác nhau của k –Số lượng các nhãn giả được chọn ngẫu nhiên. Các giá trị giữa được nội suy. Kết quả nằm trong bộ thử nghiệm của bộ dữ liệu ADR.

Tự luyện trước dựa trên sự chất lọc lặp đi lặp lại – Phần 3.1 – để chuyển kiến thức từ lần lặp này sang lần lặp tiếp theo. Mô hình chưng cất tận dụng nhiệt độ trong lớp softmax, hãy xem Phương trình 1. Tìm mức độ mà siêu thông số này có thể ảnh hưởng đến hiệu suất học tập là một thông tin hữu ích. Bảng 4 báo cáo hiệu suất mô hình ở các giá trị khác nhau của siêu tham số α . Chúng tôi thấy rằng hiệu suất cao nhất ở $\alpha = 5$. Trong phần 3.2, chúng tôi đã đề xuất một hàm mục tiêu và lập luận rằng số hạng thứ hai của hàm ngăn các nhãn cứng của tập huấn luyện xóa thông tin được chuyển từ lần lặp trước. Để chứng minh tác động của thuật ngữ thứ hai, trong Bảng 5, chúng tôi báo cáo hiệu suất mô hình ở các giá trị khác nhau của siêu tham số β –Trọng lượng của số hạng thứ hai. Chúng tôi thấy rằng hiệu suất gần như dần dần được cải thiện khi chúng tôi tăng β và đạt đỉnh ở $\beta = 0.4$. Điều này chủ yếu là do sự cải thiện về độ chính xác.

Trong Phần 3.4, chúng tôi đã đề xuất biến đổi phân phối xác suất lớp trong phép lặp +1 vào một phân phối mới giống với phân phối trong lần lặp lại. Chúng tôi lập luận rằng sự chuyển đổi này có thể giúp giảm thiểu vấn đề trôi dạt ngữ nghĩa thông qua việc hạn chế mức độ mà các nhãn giả có thể phát triển trong mỗi lần lặp lại, do đó, có thể hạn chế tác động tiêu cực của các nhãn giả ồn ào. Trong Bảng 6, chúng tôi báo cáo hiệu suất của mô hình

T	F1	Độ chính xác	Nhớ lại
2	0,422	0,361	0,514
3	0,420	0,376	0,483
4	0,421	0,356	0,517
5	0,433	0,382	0,506
6	0,422	0,370	0,491

Bảng 4: Kết quả của quá trình tự tiền luyện trong bộ thử nghiệm của bộ dữ liệu ADR ở các giá trị khác nhau của nhiệt độ (γ) để chưng cất lặp đi lặp lại.

γ	F1	Độ chính xác	Nhớ lại
0,1	0,425	0,357	0,529
0,2	0,428	0,355	0,541
0,3	0,420	0,376	0,483
0,4	0,438	0,377	0,531
0,5	0,421	0,350	0,534

Bảng 5: Kết quả Tự thử nghiệm trong bộ thử nghiệm của bộ dữ liệu ADR ở các giá trị khác nhau của siêu tham số (γ) cho quá trình học hai giai đoạn của chúng tôi – xem Công thức 2.

γ	F1	Độ chính xác	Nhớ lại
0,1	0,420	0,376	0,483
0,2	0,422	0,353	0,530
0,3	0,413	0,345	0,518
0,4	0,424	0,355	0,532
0,5	0,429	0,363	0,527

Bảng 6: Kết quả của quá trình tự tiền đào tạo trong bộ thử nghiệm của bộ dữ liệu ADR ở các giá trị khác nhau của siêu tham số (γ) đối với sự biến đổi quán tính của các nhãn giả – xem Công thức 3.

Bước đã hủy kích hoạt	F1	Độ chính xác	Nhớ lại
học hai giai đoạn	0,339	0,373	0,333
hình thang lr	0,360	0,235	0,770
chưng cất lặp đi lặp lại	0,389	0,320	0,495
biến đổi quán tính	0,420	0,365	0,497

Bảng 7: Kết quả Tự thử nghiệm trong bộ thử nghiệm của bộ dữ liệu ADR sau khi hủy kích hoạt quá trình chưng cất (Phần 3.1), học hai giai đoạn (Phần 3.2), tốc độ học hình thang (Phần 3.3), và sự biến đổi quán tính (Phần 3.4).

ở các giá trị khác nhau của siêu tham số trong Công thức 3. Siêu tham số này chi phối mức độ của phép biến đổi. Chúng tôi thấy rằng hiệu suất được cải thiện đáng kể khi chúng tôi tăng giá trị của γ . Cuối cùng, chúng tôi báo cáo một nghiên cứu cắt bỏ trong Bảng 7. Trong các thí nghiệm trước, chúng tôi đã chỉ ra rằng hiệu suất tốt hơn trong tập dữ liệu ADR có thể đạt được bằng cách điều chỉnh siêu tham số cụ thể của tập dữ liệu. Tuy nhiên, chúng tôi vẫn mong đợi rằng, với các siêu tham số hiện tại trong ADR, nghiên cứu cắt bỏ có thể tiết lộ tầm quan trọng tương đối của các mô-đun Tự thử nghiệm nói chung. Trong thử nghiệm này, chúng tôi đã thay thế mô hình đào tạo hai giai đoạn (Phần 3.2) bằng việc tăng dữ liệu đơn giản của các nhãn giả và nhãn giả. Ngoài ra, chúng tôi đã thay thế tỷ lệ học hình thang bên phải của chúng tôi (Phần 3.3) bằng tỷ lệ học tập nghiêng mặc định [18]. Chúng tôi đã thay thế quy trình chưng cất lặp đi lặp lại của mình (Phần 3.1) bằng cách sử dụng nhãn cứng trong mỗi lần lặp lại. Cuối cùng, chúng tôi đã hủy kích hoạt bước chuyển đổi nhãn giả của mình (Phần 3.4).

Tóm lại, chúng tôi đã chỉ ra rằng Tự thử nghiệm trước là kỹ thuật tiên tiến trong nhiều cài đặt. Các tác giả trong [4] chỉ ra rằng mô hình bán nghĩa - mặc dù theo sự thay đổi miền - thường thất bại khi chúng được đánh giá trên một nhiệm vụ khác với những gì chúng được đề xuất ban đầu. Do đó, họ kết luận rằng các mô hình này nên được đánh giá trong ít nhất hai bộ dữ liệu. Trong nghiên cứu này, chúng tôi đã đánh giá quá trình tự tiền đào tạo trong ba bộ dữ liệu Twitter. Chúng tôi đã chọn những đường cơ sở mạnh mẽ, tức là Tri-training với sự bất đồng [50], Sự học hỏi lẫn nhau [61], Sự lặp lại có khoảng cách [4] và Co-Decomp [30], và chỉ ra rằng một số trong số đó không thành công trong một số trường hợp nhất định. Trái ngược với những mô hình này, chúng tôi đã chứng minh rằng Tự tiền đào tạo là mô hình tốt nhất hoặc ngang bằng với mô hình tốt nhất trong mọi bối cảnh. Chúng tôi cũng đã báo cáo một loạt các thử nghiệm mà chúng tôi đã thực hiện để tiết lộ những phẩm chất của Tự tiền đào tạo. Những thử nghiệm này đã hỗ trợ về mặt kinh nghiệm cho các tuyên bố mà chúng tôi đã đưa ra trong suốt.

Nghiên cứu của chúng tôi không phải là hoàn hảo. Để tránh áp đặt bất kỳ ràng buộc nào đối với trình phân loại bên dưới, chúng tôi đề xuất rút ngẫu nhiên các tài liệu không được gắn nhãn – Thuật toán 1, Dòng 7. Tuy nhiên, nếu người ta có thể đảm bảo các thuộc tính nhất định của trình phân loại thì có lẽ chính sách lựa chọn phức tạp sẽ hiệu quả hơn. Việc áp dụng khuôn khổ của chúng tôi trong các phương thức khác, chẳng hạn như phân loại hình ảnh, cũng là một chủ đề chưa được khám phá. Công việc tương lai có thể điều tra những hướng này.

6. KẾT LUẬN

Trong nghiên cứu này, chúng tôi đã đề xuất một mô hình học tập bán giám sát được gọi là Tự học trước. Mô hình của chúng tôi được lấy cảm hứng từ thuật toán tự đào tạo truyền thống. Tự đào tạo trước sử dụng các đặc tính của mạng nơ-ron để đối phó với các vấn đề cố hữu của quá trình tự đào tạo. Đặc biệt, nó sử dụng quy trình chưng cất lặp đi lặp lại để chuyển thông tin qua các lần lặp lại. Nó cũng sử dụng mô hình đào tạo hai giai đoạn để giảm thiểu vấn đề trôi dạt ngữ nghĩa. Ngoài ra, Self-Pretraining sử dụng một lịch trình tốc độ học tập hiệu quả và một phương pháp heuristic chuyển đổi nhãn giả. Chúng tôi đã đánh giá mô hình của mình trong ba bộ dữ liệu Twitter có sẵn công khai và so sánh với sáu đường cơ sở, bao gồm cả BERT đào tạo trước. Các thử nghiệm cho thấy rằng mô hình của chúng tôi luôn hoạt động tốt hơn các đường cơ sở hiện có.

SỰ NHÌN NHẬN

Chúng tôi cảm ơn những người đánh giá ẩn danh vì phản hồi sâu sắc của họ.

NGƯỜI GIỚI THIỆU

- [1] Steven Abney. Năm 2007. *Học tập bán giám sát cho ngôn ngữ học tính toán* (Xuất bản lần 1). Chapman & Hall / CRC.
- [2] Firoj Alam, Shafiq Joty và Muhammad Imran. 2018. Thích ứng miền với Đào tạo đối phương và Nhúng đồ thị. Trong *Kỷ yếu ACL thứ 56*. Hiệp hội Ngôn ngữ học Tính toán, Melbourne, Úc, 1077–1087.
- [3] Thayer Alshaabi, David R Dewhurst, và cộng sự. 2020. Kho tiếng vang ngày càng tăng của phương tiện truyền thông xã hội: Đo lường động lực lây lan xã hội và theo thời gian cho hơn 150 ngôn ngữ trên Twitter cho năm 2009–2020. *arXiv preprint arXiv: 2003.03667* (Năm 2020).
- [4] Hadi Amiri. 2019. Tự đào tạo thần kinh thông qua sự lặp lại theo khoảng cách. Trong *Kỷ yếu Hội nghị NAAACL 2019*. Minneapolis, Minnesota, 21–31.
- [5] Eric Arazo, Diego Ortego, Paul Albert, và cộng sự. 2020. Pseudo-Labeling and Confirmation Bias in Deep Semi-Supervised Learning. Trong *Hội nghị hỗn hợp quốc tế về mạng nơ-ron năm 2020, IJCNN, ngày 19-24 tháng 7 năm 2020*. IEEE, 1–8.
- [6] David Bamman và Noah A. Smith. 2015. Phát hiện Sarcasm theo ngữ cảnh trên Twitter. Trong *Kỷ yếu ICWSM lần thứ IX*. 574–577.
- [7] Yoshua Bengio, Jérôme Louradour, Ronan Collobert và Jason Weston. 2009. Giáo trình Học tập. Trong *Kỷ yếu của ICML lần thứ 26* (Montreal, Quebec, Canada) (*ICML '09*). Hiệp hội Máy tính, New York, NY, Hoa Kỳ, 41–48.
- [8] David Berthelot, Nicholas Carlini, Ian J. Goodfellow, Nicolas Papernot, Avital Oliver và Colin Raffel. 2019. MixMatch: Phương pháp tiếp cận toàn diện đối với học tập bán giám sát. Trong *NeurIPS 2019, 8-14 Vancouver, BC, Canada*. 5050–5060.

- [9] Avrim Blum và Tom M. Mitchell. 1998. Kết hợp dữ liệu được gắn nhãn và không được gắn nhãn với đồng đạo tạo. Trong *Kỷ yếu của COLT lần thứ 11, 1998, Madison, Wisconsin, Hoa Kỳ, 24-26 tháng 7 năm 1998*:92–100.
- [10] Tom B Brown, Benjamin Mann, và cộng sự. 2020. Mô hình ngôn ngữ là những người học rất ít. *arXiv preprint arXiv: 2005.14163*(Năm 2020).
- [11] Cristian Buciluundefined, Rich Caruana, và Alexandru Niculescu-Mizil. 2006. Nén mô hình. Trong *Kỷ yếu của ACM SIGKDD thứ 12*(Philadelphia, PA, Hoa Kỳ)(*KDD '06*). 535–541.
- [12] Andrew Carlson, Justin Betteridge, Bryan Kiesel, Burr Settles, Estevam R. Hruschka và Tom M. Mitchell. 2010. Hướng tới một Kiến trúc cho việc Học Ngôn ngữ Không bao giờ Kết thúc. Trong *Kỷ yếu AAAI lần thứ 24*. 1306–1313.
- [13] Paola Cascante-Bonilla, Fuwen Tan, Yanjun Qi và Vicente Ordonez. 2020. Dẫn nhãn chương trình giảng dạy: Dẫn nhãn giả theo nhịp độ cho việc học bán có giám sát. *arXiv bản in trước arXiv: 2001.06001*(Năm 2020).
- [14] Olivier Chapelle, Bernhard Schölkopf và Alexander Zien (Eds.). Năm 2006. *Học tập bán giám sát*. Báo chí MIT.
- [15] Ting Chen, Simon Kornblith, Mohammad Norouzi và Geoffrey Hinton. 2020. Một khuôn khổ đơn giản để học tương phản về biểu diễn trực quan. *arXiv preprint arXiv: 2002.05709*(Năm 2020).
- [16] Ting Chen, Simon Kornblith, Kevin Swersky, Mohammad Norouzi và Geoffrey Hinton. 2020. Các mô hình tự giám sát lớn là những người học bán giám sát mạnh mẽ. *arXiv preprint arXiv: 2006.10029*(Năm 2020).
- [17] James R Curran, Tara Murphy và Bernhard Scholz. 2007. Giảm thiểu sự trôi dạt ngữ nghĩa với khởi động loại trừ lẫn nhau. Trong *Kỷ yếu Hội nghị lần thứ 10 của Hiệp hội Ngôn ngữ học Tính toán Thái Bình Dương*, Tập 6. Bali, 172–180.
- [18] Jacob Devlin, Ming-Wei Chang, Kenton Lee, và Kristina Toutanova. 2019. BERT: Đào tạo trước về Máy biến áp hai chiều sâu để hiểu ngôn ngữ. Trong *Proc của NAACL 2019*. 4171–4186.
- [19] Tommaso Furlanello, Zachary Chase Lipton, Michael Tschannen, Laurent Itti và Anima Anandkumar. 2018. Born-Again Neural Networks. Trong *Kỷ yếu ICML lần thứ 35, Stockholm, Thụy Điển, ngày 10-15 tháng 7 năm 2018*, Tập 80. 1602–1611.
- [20] Roberto Gonzalez-Ibaez, Smaranda Muresan và Nina Wacholder. 2011. Xác định Sarcasm trong Twitter: Một cái nhìn gần hơn. Trong *Kỷ yếu của ACL lần thứ 49*(Portland, Oregon)(*HLT '11*). 581–586.
- [21] Suchin Gururangan, Tam Dang, Dallas Card, và Noah A. Smith. 2019. Đào tạo trước biến thể cho Phân loại văn bản bán giám sát. Trong *Kỷ yếu của ACL lần thứ 57*. Florence, Ý, 5880–5894.
- [22] Suchin Gururangan, Ana Marasović, Swabha Swayamdipta, Kyle Lo, Iz Beltagy, Doug Downey và Noah A. Smith. 2020. Không ngừng thử nghiệm trước: Điều chỉnh mô hình ngôn ngữ cho miền và nhiệm vụ. Trong *Kỷ yếu của ACL*.
- [23] Junxian He, Jiatao Gu, Jiajun Shen, và Marc'Aurelio Ranzato. 2020. Kiểm tra lại quá trình tự đào tạo để tạo chuốt thần kinh. Trong *Hội nghị quốc tế lần thứ 8 về đại diện học tập, ICLR 2020, ngày 26-30 tháng 4 năm 2020*. OpenReview.net.
- [24] Dan Hendrycks, Kimin Lee và Mantas Mazeika. 2019. Sử dụng đào tạo trước có thể cải thiện độ chắc chắn và độ không chắc chắn của mô hình. Trong *Kỷ yếu của ICML lần thứ 36, California, Hoa Kỳ, Tập 97*. 2712–2721.
- [25] Geoffrey Hinton, Oriol Vinyals và Jeff Dean. 2015. Chất lọc kiến thức trong mạng nơ-ron. *arXiv bản in trước arXiv: 1503.02531*(2015).
- [26] Nils Holzenberger, Andrew Blair-Stanek và Benjamin Van Durme. 2020. Tập dữ liệu về lý luận theo luật định trong việc thi hành luật thuế và trả lời câu hỏi. *arXiv bản in trước arXiv: 2005.05257*(Năm 2020).
- [27] Jeremy Howard và Sebastian Ruder. 2018. Tinh chỉnh Mô hình Ngôn ngữ Phổ thông để Phân loại Văn bản. Trong *Kỷ yếu ACL thứ 56*. 328–339.
- [28] Xiaolei Huang, Michael C Smith, Michael J Paul, Dmytro Ryzhkov, Sandra C Quinn, David A Broniatowski và Mark Dredze. 2017. Kiểm tra các mô hình tiềm phòng cúm trên mạng xã hội. Trong *Hội thảo tài AAAl lần thứ 31*.
- [29] Payam Karisani và Eugene Agichtein. 2018. Bạn Thực Sự Vừa Bị Đầu Tim? Hướng tới phát hiện mạnh mẽ các đề cập đến sức khỏe cá nhân trên phương tiện truyền thông xã hội. Trong *Kỷ yếu của Hội nghị World Wide Web 2018*(Lyon, Pháp). 137–146.
- [30] Payam Karisani, Joyce Ho và Eugene Agichtein. 2020. Phân rã nhiệm vụ do miền hướng dẫn với tự đào tạo để phát hiện sự kiện cá nhân trên phương tiện truyền thông xã hội. Trong *Kỷ yếu Hội nghị Web 2020*(Đài Bắc, Đài Loan). 2411–2420.
- [31] James Kirkpatrick, Razvan Pascanu, và cộng sự. 2017. Khắc phục tình trạng lãng quên thảm khốc trong mạng nơ-ron. *Kỷ yếu của Viện Hàn lâm Khoa học Quốc gia* 114, 13 (2017), 3521–3526.
- [32] Samuli Laine và Timo Aila. 2017. Tập hợp tạm thời cho học tập bán giám sát. Trong *Hội nghị quốc tế lần thứ 5 về đại diện học tập, ICLR 2017, Toulon, Pháp, 24-26 tháng 4 năm 2017, Kỷ yếu theo dõi hội nghị*.
- [33] Dong-Hyun Lee. 2013. Pseudo-label: Phương pháp học bán giám sát đơn giản và hiệu quả dành cho mạng nơ-ron sâu. Trong *Hội thảo về những thách thức trong học đại diện, ICML, Tập 3*.
- [34] jinhyuk Lee, Wonjin Yoon, và cộng sự. 2019. BioBERT: mô hình biểu diễn ngôn ngữ y sinh được đào tạo trước để khai thác văn bản y sinh. *Tin sinh học* 36, 4 (09 2019), 1234–1240.
- [35] Kimin Lee, Kibok Lee, Honglak Lee và Jinwoo Shin. 2018. Khung thống nhất đơn giản để phát hiện các mẫu ngoài phân phối và các cuộc tấn công bất lợi. Trong *Những tiến bộ trong hệ thống xử lý thông tin thần kinh* 31. 7167–7177.
- [36] Michael McCloskey và Neal J. Cohen. 1989. Can thiệp thảm khốc trong mạng kết nối: Vấn đề học tập tuần tự. *Tâm lý học và Động lực*, Vol. 24. Báo chí Học thuật, 109 – 165.
- [37] Richard McCreadie, Cody Buntain và Ian Soboroff. 2019. Luồng sự cố TREC: Tìm kiếm thông tin hữu ích trên phương tiện truyền thông xã hội. Trong *Kỷ yếu IS-CRAM lần thứ 16, năm 2019*.
- [38] Tom M Mitchell và cộng sự. 1997. Máy học. Năm 1997. *Burr Ridge, IL: McGraw Hill* 45, 37 (1997), 870–877.
- [39] Subhabrata Mukherjee và Ahmed Hassan Awadallah. 2020. Tự đào tạo về Nhận thức không chắc chắn về Phân loại văn bản có ít nhãn. arXiv: 2006.15315 [cs.CL]
- [40] Gabriel Pereyra, George Tucker, Jan Chorowski, Lukasz Kaiser và Geoffrey E. Hinton. 2017. Quy định hóa mạng lưới thần kinh bằng cách trừng phạt các phân phối đầu ra đáng tin cậy. Trong *ICLR lần thứ 5 năm 2017, Toulon, Pháp, ngày 24-26 tháng 4 năm 2017*.
- [41] Matthew Peters, Mark Neumann, Mohit Iyyer, Matt Gardner, Christopher Clark, Kenton Lee và Luke Zettlemoyer. 2018. Trình bày từ ngữ theo ngữ cảnh sâu sắc. Trong *Kỷ yếu NAACL 2018*. New Orleans, Louisiana, 2227–2237.
- [42] Siyuan Qiao, Wei Shen, Zhishuai Zhang, Bo Wang và Alan Yuille. 2018. Đồng đạo tạo sâu về Nhận dạng hình ảnh bán giám sát. Trong *Kỷ yếu của Hội nghị Châu Âu về Thị giác Máy tính (ECCV)*.
- [43] Colin Raffel và cộng sự. 2019. Khám phá các giới hạn của việc học chuyển đổi với một máy biến văn bản thành văn bản thống nhất. *arXiv bản in trước arXiv: 1910.10683*(2019).
- [44] Sebastian Ruder và Barbara Plank. 2018. Cơ sở vững chắc cho việc học bán giám sát bằng thần kinh theo Domain Shift. Trong *Kỷ yếu ACL thứ 56*(Melbourne, Úc). Hiệp hội Ngôn ngữ học Tính toán, 1044–1054.
- [45] Kuniaki Saito, Yoshitaka Ushiku, và Tatsuya Harada. 2017. Tri-Training bất đối xứng để thích ứng miền không giám sát. Trong *Kỷ yếu của ICML lần thứ 34* (Sydney, NSW, Úc)(*ICML '17*). 2988–2997.
- [46] M. Sajjadi, M. Javanmardi và T. Tasdizen. 2016. Mất độc quyền lẫn nhau đối với học sâu bán giám sát. Trong *IEEE 2016 (ICIP)*. 1908–1912.
- [47] Dale Schuurmans và Finnegan Southey. 2002. Các phương pháp dựa trên số liệu để lựa chọn và điều chỉnh mô hình thích ứng. *Học máy* 48, 1 (2002), 51–84.
- [48] H Scudder. 1965. Xác suất lỗi của một số máy nhận dạng mẫu thích ứng. *Giao dịch IEEE trên lý thuyết thông tin* 11, 3 (1965), 363–371.
- [49] Weiwei Shi, Yihong Gong, Chris Ding, Zhiheng MaXiaoYu Tao và Nanning Zheng. 2018. Học sâu bán giám sát chuyển đổi sử dụng các tính năng tối thiểu. Trong *Kỷ yếu của (ECCV)*. 299–315.
- [50] Anders Segaaard. 2010. Đào tạo bán giám sát đơn giản cho người gần thể theo phân của không nói. Trong *Kỷ yếu ACL 2010*(Uppsala, Thụy Điển). Hoa Kỳ, 205–208.
- [51] Baochen Sun, Jiashi Feng và Kate Saenko. 2016. Sự trở lại của khả năng thích ứng miền dễ dàng đáng thất vọng. Trong *Kỷ yếu AAAI lần thứ ba, ngày 12 - 17 tháng 2 năm 2016, Phoenix, Arizona, Hoa Kỳ*. 2058–2065.
- [52] Antti Tarvainen và Harri Valpola. 2017. Giáo viên trung bình là hình mẫu tốt hơn: Các mục tiêu nhất quán trung bình theo trọng số cải thiện kết quả học sâu bán giám sát. Trong *Những tiến bộ trong hệ thống xử lý thông tin thần kinh* 30. 1195–1204.
- [53] Davy Weissenbacher và Graciela Gonzalez-Hernandez (Eds.). Năm 2019. *Kỷ yếu Hội thảo Khai thác Truyền thông Xã hội cho Ứng dụng Y tế (# SMM4H) lần thứ tư & Nhiệm vụ được Chia sẻ*. Hiệp hội Ngôn ngữ học Tính toán, Florence, Ý.
- [54] Thomas Wolf, Lysandre Debut, và cộng sự. 2019. Người vận chuyển của HuggingFace: Xử lý ngôn ngữ tự nhiên tiên tiến nhất. *ArXivabs / 1910.03771* (2019).
- [55] Jiawei Wu, Lei Li, và William Yang Wang. 2018. Đồng đạo tạo được củng cố. Trong *Kỷ yếu NAACL 2018*. New Orleans, Louisiana, 1252–1262.
- [56] Qizhe Xie, Zihang Dai, Eduard Hovy, Minh-Thang Luong, and Quoc V Le. 2019. Tăng cường dữ liệu không giám sát để đào tạo tính nhất quán. *arXiv bản in trước arXiv: 1904.12848*(2019).
- [57] Qizhe Xie, Minh-Thang Luong, Eduard Hovy, and Quoc V. Le. 2020. Tự Đào Tạo Với Sinh Viên Ôn ào Cải thiện Phân loại ImageNet. Trong *Kỷ yếu của Hội nghị IEEE / CVF về Thị giác Máy tính và Nhận dạng Mẫu (CVPR)*.
- [58] David Yarowsky. 1995. Không giám sát Word Sense Disambiguation Rivaling Phương pháp giám sát. Trong *ACL thứ 33*. Cambridge, Massachusetts, Hoa Kỳ, 189–196.
- [59] Kiran Zahra, Muhammad Imran và Frank O. Ostermann. 2020. Tự động nhận dạng tin nhắn của nhân chứng trên twitter trong các thảm họa. *Xử lý và quản lý thông tin* 57, 1 (2020), 102107.
- [60] Hongyi Zhang, Moustapha Cissé, Yann N. Dauphin, và David Lopez-Paz. 2018. mixup: Vượt ra ngoài Giảm thiểu rủi ro theo kinh nghiệm. Trong *ICLR lần thứ 6 năm 2018, Vancouver, BC, Canada, 30 tháng 4 - 3 tháng 5 năm 2018, Kỷ yếu theo dõi hội nghị*.
- [61] Ying Zhang, Tao Xiang, Timothy M. Hospedales, và Huchuan Lu. 2018. Học hỏi lẫn nhau sâu sắc. Trong *Hội nghị IEEE về Thị giác Máy tính và Nhận dạng Mẫu (CVPR)*.